

TWFE con Adopción Escalonada

Bacon, Callaway & Sant'Anna, y Análisis de Eventos

Econometría Avanzada — Javeriana · 2026-1

Plan de la clase


Parte	Tema
1	Repaso: TWFE en el caso 2×2
2	El problema: adopción escalonada
3	Descomposición de Goodman-Bacon (+ ejercicio Excel)
4	Callaway & Sant'Anna — la solución
5	Análisis de eventos (event study)

Abran el do-file `11_stata_v2.do` y corran la **Sección 0** (instalar paquetes) antes de empezar.

Parte 1

DiD 2x2: la situación ideal


Dos grupos (tratado / control), dos períodos (antes / después):



Con 2 grupos y 2 períodos, TWFE es **perfecto**: bajo tendencias paralelas identifica el ATT sin ningún supuesto adicional.

TWFE en panel largo – mismo timing

¿Qué pasa cuando tenemos muchos períodos pero todos adoptan el tratamiento al mismo tiempo?




```
reghdfe Y D, absorb(id t) cluster(id)
```

Sigue funcionando bien: hay un solo "evento" y la comparación es siempre tratado vs control puro.

Parte 2


Staggered adoption: distintos tiempos de entrada

Las unidades adoptan el tratamiento en **momentos distintos**:



id=2 trata desde **1985** ($\tau = 2$) · id=3 trata desde **1988** ($\tau = 4$) · id=1 nunca trata

Lo que ve TWFE: Y con adopción escalonada



```
reghdfe Y D, absorb(id t) cluster(id)
```

```
* →  $\hat{\beta}_{TWFE} = 2.71$ 
```

$\hat{\beta}_{TWFE} = 2.71$ pero ATT verdadero = 2.57. ¿Por qué difieren? ¿Qué comparaciones está haciendo TWFE internamente?

El ATT verdadero — calculémoslo

id=2 tiene **5 períodos** tratados (1985–1989) con $\tau = 2$.

id=3 tiene **2 períodos** tratados (1988–1989) con $\tau = 4$.

```
di "ATT_overall = " (5*2 + 2*4) / 7
```

```
ATT_overall = 2.5714286
```

$$ATT_{overall} = \frac{5 \times 2 + 2 \times 4}{7} = \frac{18}{7} \approx 2.57$$

TWFE dio $2.71 \neq 2.57$. No es enorme aquí. Pero: ¿qué pasa si los efectos fueran más distintos? ¿O si id=3 llegara tarde cuando casi todos ya están tratados? El sesgo puede ser mucho mayor — y en casos extremos puede cambiar el **signo**.

Parte 3

La intuición central

Resultado de Bacon: con adopción escalonada, TWFE es un **promedio ponderado** de **todas** las comparaciones DiD 2×2 posibles entre pares de grupos.

$$\hat{\beta}^{TWFE} = \sum_k w_k \hat{\beta}_k^{(2 \times 2)}$$

Los pesos w_k :

- Son **siempre positivos** (suman a 1)
- Dependen del tamaño relativo del par y de la varianza del tratamiento

Los pesos de Bacon son siempre positivos. El problema es otro: **algunas comparaciones 2×2 usan como control a unidades que ya están tratadas.**

¿Cómo se calcula cada $\hat{\beta}_k^{(2 \times 2)}$?

El mismo DGP del libro: $Y_{it} = \tau_i \cdot D_{it}$ — es decir, **Y=0** si no tratado, **Y=τ** si tratado

Para cada comparación: DiD = $(\bar{Y}_{\text{trat,post}} - \bar{Y}_{\text{trat,pre}}) - (\bar{Y}_{\text{ctrl,post}} - \bar{Y}_{\text{ctrl,pre}})$

Comparación	Ventana · pre / post	$\Delta \bar{Y}_{\text{trat}}$	$\Delta \bar{Y}_{\text{ctrl}}$	$\hat{\beta}_k$
Never vs Early	80–89 · pre:<85 · post:≥85	$2 - 0 = 2$	$0 - 0 = 0$	2
Never vs Late	80–89 · pre:<88 · post:≥88	$4 - 0 = 4$	$0 - 0 = 0$	4
Early vs Late ✓	80– 87 · pre:<85 · post:85-87	$2 - 0 = 2$	$0 - 0 = 0$	2
Late vs Early ✗	85 –89 · pre:<88 · post:≥88	$4 - 0 = 4$	2 – 2 = 0	4

Fila **Early vs Late** ✓: en 1985-87 id=3 aún no trata → su $Y=0$, $\Delta=0$.

Fila **Late vs Early** ✗: id=2 ya tiene $\tau=2$ **constante** desde 1985 → en 1985-87 $Y=2$, en 1988-89 $Y=2$ también → $\Delta=\mathbf{2-2=0}$ → no contamina. El sesgo aparece si τ_2 **crece** con el tiempo.

¿Cómo se construyen los pesos?

Cada comparación 2x2 usa una **ventana temporal** distinta. OLS pondera más donde hay más variación en D_{it} :


$$w_k \propto \underbrace{\text{obs en la ventana}}_{\text{tamaño}} \times \underbrace{\bar{D}_k(1 - \bar{D}_k)}_{\text{varianza de D en esa ventana}}$$

En nuestro ejemplo — cada comparación usa solo el **par de grupos relevante**:

Comparación	Grupos	Ventana	Obs del par	Peso <code>bacondecomp</code>
Never vs Timing (id=1 vs id=2)	2 unidades	1980–1989	20	parte de 0.661
Never vs Timing (id=1 vs id=3)	2 unidades	1980–1989	20	parte de 0.661
Early vs Late (id=2 vs id=3)	2 unidades	1980–1987	16	0.242
Late vs Early (id=3 vs id=2)	2 unidades	1985–1989	10	0.097

"Never vs Timing" agrupa las dos primeras filas — 20 obs cada una, ventana larga → peso alto (66%). "Late vs Early" tiene la ventana más corta (10 obs) → peso bajo (10%). Los **números exactos** los calcula `bacondecomp` internamente.

Las 3 familias de comparaciones



Tipo	Tratado	Control	¿Limpia?
Never vs Timing	id=2 ó id=3	id=1 (nunca)	✓
Early vs Late	id=2	id=3 (aún no trata)	✓
Late vs Early	id=3	id=2 (ya tratado)	✗

La comparación sucia — paso a paso

Late vs Early estima el efecto de id=3 usando a id=2 como "control" en 1985–1989:

Año:	1985	1986	1987	1988	1989	
id=2 (D):	1	1	1	1	1	← YA TRATADO (actúa como "control")
id=3 (D):	0	0	0	1	1	← TRATADO desde 1988

Lo que calcula:

$$(Y_{\{3,post\}} - Y_{\{3,pre\}}) - (Y_{\{2,post\}} - Y_{\{2,pre\}})$$

Si $\tau_{\{id=2\}}$ es CONSTANTE $\rightarrow Y_{\{2,post\}} - Y_{\{2,pre\}} \approx 0 \rightarrow$ no contamina ✓

Si $\tau_{\{id=2\}}$ CRECE con el tiempo $\rightarrow Y_{\{2,post\}} - Y_{\{2,pre\}} > 0 \rightarrow$ resta demás ✗

En nuestro ejemplo $\tau_{\{id=2\}} = 2$ constante $\rightarrow$ el sesgo es pequeño (2.71 vs 2.57). Con efectos que crecen con el tiempo de exposición, el sesgo puede ser mucho mayor.

Diagnóstico — Ejemplo del libro (3 unidades)

* Sección 5 del do-file — ejemplo con id=1,2,3
bacondecomp Y **D**, ddetail

Bacon Decomposition

Comparison	Beta	Weight
Never/Always vs Timing	2.7826	0.6613
Earlier Treated vs Later Ctrl	2.0000	0.2419
Later Treated vs Earlier Ctrl	4.0000	0.0968
β_{TWFE}	2.7097	1.0000

- **Never vs Timing (66%)**: comparaciones limpias ✓ — β mezcla $\tau_2=2$ y $\tau_3=4$
- **Earlier vs Later (24%)**: id=2 tratado, id=3 aún no — limpia ✓ — $\beta=2$ ✓
- **Later vs Earlier (10%)**: id=3 tratado, id=2 **ya tratado** como control — **sucia** ✗

Diagnóstico — Ejercicio Pausa (8 unidades)

* Después de la Pausa – corra `bacondecomp` en el panel de 8 unidades
`bacondecomp Y D, ddetail`

Bacon Decomposition

Comparison	Beta	Weight
Never/Always vs Timing	~2.8	~0.55
Earlier Treated vs Later Ctrl	~2.4	~0.30
Later Treated vs Earlier Ctrl	~4.8	~0.15
β_{TWFE}	~3.22	1.0000

Comparar con el ATT verdadero:

```
di "ATT = (2*5*2 + 2*3*3 + 2*1*5) / 18 = " (2*5*2 + 2*3*3 + 2*1*5)/18
* ATT ≈ 2.67
```

$\hat{\beta}_{TWFE} \approx 3.22 \neq ATT \approx 2.67$. "Later vs Earlier" (peso ~15%) tiene $\beta \approx 4.8$ — unidades con $\tau=5$ usando como control unidades ya tratadas con $\tau=2$. El sesgo es mayor porque los efectos varían más entre cohortes.

II Pausa — Ejercicio Stata

8 unidades · 3 grupos que adoptan · 6 períodos

Paso 1 — Crear el panel con 3 grupos de adopción

```
clear
set obs 48
gen id = ceil(_n/6)          // id = 1 a 8
gen t = mod(_n-1, 6) + 1    // t = 1 a 6
sort id t
xtset id t

* id=1,2: nunca tratados
* id=3,4: tratan en t=2 (EARLY),  $\tau = 2$ 
* id=5,6: tratan en t=4 (MEDIUM),  $\tau = 3$ 
* id=7,8: tratan en t=6 (LATE),  $\tau = 5$ 
gen D = 0
replace D = 1 if inlist(id,3,4) & t >= 2
replace D = 1 if inlist(id,5,6) & t >= 4
replace D = 1 if inlist(id,7,8) & t >= 6

gen Y = 0
replace Y = 2 if inlist(id,3,4) & D == 1 //  $\tau=2$  para EARLY
replace Y = 3 if inlist(id,5,6) & D == 1 //  $\tau=3$  para MEDIUM
replace Y = 5 if inlist(id,7,8) & D == 1 //  $\tau=5$  para LATE

list id t D Y, sep(6)
```

Antes de continuar: ¿cuántas obs tienen D=1? ¿Cuántos grupos adoptan tratamiento?

Paso 2 — ATT verdadero y TWFE

```
* — ATT verdadero —————
* id=3,4: 5 per × 2 units ×  $\tau=2$  = 20
* id=5,6: 3 per × 2 units ×  $\tau=3$  = 18
* id=7,8: 1 per × 2 units ×  $\tau=5$  = 10
* obs tratadas = 10 + 6 + 2 = 18
di "ATT verdadero = " (2*5*2 + 2*3*3 + 2*1*5) / 18 // → 2.67
```

```
* — TWFE —————
reghdfe Y D, absorb(id t) vce(robust)
* Anoten  $\hat{\beta}_{TWFE}$ . ¿Es igual al ATT?
```

ATT verdadero = 2.6667

Y	Coef.
---	-------

D	3.2222
---	--------

D | 3.2222 ← $\hat{\beta}_{TWFE} \neq \text{ATT}$

ATT = 2.67 · $\hat{\beta}_{TWFE}$ ≈ 3.22. Diferencia = +0.56. Ahora vamos a entender **de dónde viene**.

Paso 3 — Las 3 comparaciones LIMPIAS (vs nunca tratados)

```
* DiD_1: Early vs Nunca (control puro = id=1,2)
xtreg Y D i.t if inlist(id,1,2,3,4), fe robust
di "DiD_1 (Early vs Nunca) = " _b[D] // → 2

* DiD_2: Medium vs Nunca (control puro = id=1,2)
xtreg Y D i.t if inlist(id,1,2,5,6), fe robust
di "DiD_2 (Medium vs Nunca) = " _b[D] // → 3

* DiD_3: Late vs Nunca (control puro = id=1,2)
xtreg Y D i.t if inlist(id,1,2,7,8), fe robust
di "DiD_3 (Late vs Nunca) = " _b[D] // → 5
```

Las tres comparaciones con nunca-tratados recuperan exactamente $\tau=2$, $\tau=3$, $\tau=5$. ✓

Retroalimentación — comparaciones entre grupos con tratamiento

La profesora corre el código — los estudiantes observan

Retroalimentación — Las 3 comparaciones SUCIAS

```
* DiD_4: Medium vs Early — Early YA está tratado desde t=2
gen D_med = D * inlist(id,5,6)
xtreg Y D_med i.t if inlist(id,3,4,5,6) & t>=2, fe robust
di "DiD_4 (Medium vs Early) = " _b[D_med] // → 3

* DiD_5: Late vs Early — Early YA está tratado desde t=2
gen D_late = D * inlist(id,7,8)
xtreg Y D_late i.t if inlist(id,3,4,7,8) & t>=2, fe robust
di "DiD_5 (Late vs Early) = " _b[D_late] // → 5

* DiD_6: Late vs Medium — Medium YA está tratado desde t=4
xtreg Y D_late i.t if inlist(id,5,6,7,8) & t>=4, fe robust
di "DiD_6 (Late vs Medium) = " _b[D_late] // → 5
```

Las tres usan como "control" a un grupo **ya tratado**. Con τ constante recuperan el valor correcto — pero eso es por suerte. Con efectos dinámicos, ya no.

Retroalimentación — Resultados y discusión

#	Comparación	β_k	¿Control limpio?	¿Recupera τ ?
1	Early vs Nunca	2.0	✓ Nunca tratado	$\tau=2$ ✓
2	Medium vs Nunca	3.0	✓ Nunca tratado	$\tau=3$ ✓
3	Late vs Nunca	5.0	✓ Nunca tratado	$\tau=5$ ✓
4	Medium vs Early	3.0	✗ Early tratado	$\tau=3$ ✓*
5	Late vs Early	5.0	✗ Early tratado	$\tau=5$ ✓*
6	Late vs Medium	5.0	✗ Medium tratado	$\tau=5$ ✓*

β_{TWFE} (promedio ponderado de todas) ≈ 3.22 $ATT = 2.67$

(*) **Sorpresa:** Con efectos **constantes** las comparaciones sucias recuperan τ correcto.
El sesgo de TWFE viene de los **pesos** (no de DiDs incorrectos).

Con efectos **dinámicos** (τ crece con el tiempo de exposición), las DiDs sucias ya no recuperarían τ correcto → ahí el problema es grave → **usar CS**.

¿Cuándo es un problema serio?

Regla práctica: miren el peso de "Later vs Earlier"

Peso de "Late vs Early"	Efectos dinámicos (crecen con exposición)	¿Problema?
< 10%	Cualquiera	Pequeño
10–25%	No (efectos constantes)	Pequeño
10–25%	Sí	Moderado → considerar CS
> 25%	Sí	Serio → usar CS

* Ver la fracción de peso "contaminada":

`bacondecomp Y D, ddetail`

* → mirar el peso de "Later Treated vs Earlier Control"

Nuestro ejemplo: peso = **9.7%** → problema pequeño. En paneles con pocos controles puros y muchos grupos escalonados ese porcentaje puede superar el 30–40%.

Parte 4

La solución: Callaway & Sant'Anna (2021)

CS en tres pasos

Paso 1 — Estimar $ATT(g,t)$ para cada cohorte-período

$$ATT(g, t) = E[Y_{it}(g) - Y_{it}(0) \mid G_i = g]$$

Cada cohorte g se compara solo con unidades **nunca tratadas** (o no-aún-tratadas). No hay comparaciones sucias.

Paso 2 — Agregar según lo que necesitas

<code>estat simple</code>	* ATT overall (un solo número – este va al paper)
<code>estat calendar</code>	* ATT por año de calendario
<code>estat group</code>	* ATT por cohorte de tratamiento
<code>estat event</code>	* ATT por período relativo (event study)

Paso 3 — Graficar

<code>csdid_plot</code>	* event study con intervalos de confianza simultáneos
-------------------------	---

Preparar datos y correr `csdid`

```
* gvar = primer período de tratamiento (0 = nunca tratado)
gen gvar = .
replace gvar = 1985 if id == 2
replace gvar = 1988 if id == 3
replace gvar = 0    if id == 1

* Estimar
csdid Y, ivar(id) time(t) gvar(gvar) notyet
```

Callaway & Sant'Anna (2021) Difference-in-Differences

ATT	Coef.	Std. Err.
ATT(1985,1985)	2.0000	.
ATT(1985,1986)	2.0000	.
ATT(1985,1987)	2.0000	.
ATT(1985,1988)	2.0000	.
ATT(1985,1989)	2.0000	.
ATT(1988,1988)	4.0000	.
ATT(1988,1989)	4.0000	.

CS recupera exactamente $\tau=2$ para cohorte 1985 y $\tau=4$ para cohorte 1988.

El ATT overall y el event study

```
estat simple
```

```
Average Treatment Effect:  
ATT | 2.5714 (vs  $\hat{\beta}_{TWFE} = 2.7097$ )
```

```
estat event  
csdid_plot, title("Event study: Callaway & Sant'Anna")
```

CS da ATT = 2.57, el valor verdadero. TWFE daba 2.71 (+0.14 de sesgo). En datos reales la diferencia puede ser mucho mayor — y de distinto signo.
notyet : usa no-aún-tratados como controles adicionales (más eficiente; requiere no-anticipación).

Parte 5

Event Study

¿Qué queremos mostrar?

En lugar de un solo β , estimamos el efecto en **cada período** relativo al tratamiento:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \delta_k \cdot \mathbf{1}[t - G_i = k] + \varepsilon_{it}$$

Período	Qué muestra
$k = -4, -3, -2, -1$	Pre-tratamiento → deben ser ≈ 0 (prueba de tendencias paralelas)
$k = -1$	Referencia — siempre = 0 por construcción (se omite)
$k = 0, 1, 2, \dots$	Post-tratamiento → magnitud y dinámica del efecto

Un event study bien hecho hace dos cosas a la vez: **valida el diseño** (coefs pre = 0) y **describe la dinámica** (coefs post).

Paso 1 — Crear tiempo relativo y dummies

```
* Tiempo relativo al tratamiento
gen rel_time = t - gvar
replace rel_time = . if gvar == 0      // nunca tratados: sin rel_time

* Dummies pre (leads): F_1 = 1 año antes, F_2 = 2 años antes, ...
forvalues k = 1/5 {
    gen F_`k' = (rel_time == -`k')
}

* Dummies post (lags): L_0 = año del tratamiento, L_1, L_2, ...
forvalues k = 0/4 {
    gen L_`k' = (rel_time == `k')
}

* F_1 es la categoría de referencia → se omite de la regresión
```

¿Por qué omitir $k = -1$? Necesitamos una categoría de referencia. $k = -1$ (un año antes del tratamiento) es el estándar: en ese período por definición no hay efecto, y medir todo relativo a ese punto es lo más intuitivo.


Paso 2 — Regresión y gráfico

```
* Event study TWFE (F_1 omitido = referencia)
reghdfe Y F_5 F_4 F_3 F_2 L_0 L_1 L_2 L_3 L_4, ///
        absorb(id t) cluster(id)
```

Y	Coef.	
F_5	0.0000	← pre k=-5 ✓ (=0: sin diferencia 5 años antes)
F_4	0.0000	← pre k=-4 ✓
F_3	0.0000	← pre k=-3 ✓
F_2	0.0000	← pre k=-2 ✓
(F_1=ref)	0.0000	← referencia
L_0	2.2857	← efecto en el año del tratamiento
L_1	2.2857	← efecto 1 año después
L_2	2.2857	← efecto 2 años después
L_3	2.2857	← efecto 3 años después
L_4	3.0000	← solo id=3 tiene k=4 ($\tau=4$) → sube

Paso 3 — Graficar

```
coefplot, keep(F_5 F_4 F_3 F_2 L_0 L_1 L_2 L_3 L_4) ///  
  rename(F_5="-5" F_4="-4" F_3="-3" F_2="-2" ///  
    L_0="0" L_1="1" L_2="2" L_3="3" L_4="4") ///  
  vertical yline(0) xline(4.5, lp(dash) lc(red)) ///  
  xtitle("Período relativo al tratamiento") ///  
  ytitle("Coeficiente estimado") title("Event study TWFE")
```



Cómo leer e interpretar

Coeficientes pre-tratamiento (F_5 ... F_2) todos = 0:

✓ **Tendencias paralelas** — antes del tratamiento no había diferencias sistemáticas entre tratados y controles. El diseño es válido.

Prueba formal:

```
test F_5 F_4 F_3 F_2    // H0: todos los pre-trend = 0
                        // No rechazar → tendencias paralelas ✓
```

Coeficientes post (L_0 ... L_3 ≈ 2.29, L_4 = 3.0):

El efecto es positivo y sostenido. L_4 sube porque en k=4 solo id=3 contribuye ($\tau=4$). Esto es una señal de **heterogeneidad de efectos** entre cohortes — exactamente el problema que describe Bacon.

Event study limpio: usar CS

Para un paper, el event study de CS es preferible cuando hay staggered adoption:

```
csdid Y, ivar(id) time(t) gvar(gvar) notyet
estat event
csdid_plot, title("Event study CS – sin comparaciones sucias")
```

Diferencia entre TWFE y CS:

TWFE event study:

L_0=2.29 L_1=2.29 L_2=2.29 L_3=2.29 L_4=3.00

→ mezcla efectos de cohorte 1985 ($\tau=2$) y cohorte 1988 ($\tau=4$)

CS event study (estat event):

k=0: 2.57 k=1: 2.57 k=2: 2.57 ...

→ promedio limpio ponderado por observaciones tratadas

CS usa solo comparaciones limpias → el event study refleja mejor la dinámica real del efecto.

Estimadores modernos — en el do-file

El do-file (Sección 7) tiene código completo. Disponibles para su investigación:

Comando	Método	Cuándo usarlo
<code>csdid</code>	Callaway & Sant'Anna (2021)	Punto de partida — estándar
<code>did_imputation</code>	Borusyak et al. (2021)	Más eficiente con efectos estáticos
<code>eventstudyinteract</code>	Sun & Abraham (2021)	Event study interactuado
<code>did2s</code>	Gardner (2021)	Rápido, buena alternativa
<code>did_multipltgt_dyn</code>	de Chaisemartin et al. (2024)	Efectos dinámicos complejos
<code>stackedev</code>	Cengiz et al. (2019)	Panel apilado
<code>jwddid</code>	Wooldridge (2021)	GMM, covariables fácil

Resumen

Pregunta	Respuesta
¿Los pesos de Bacon son negativos?	No — siempre positivos
¿Cuál es el problema de Bacon?	Algunas comparaciones usan ya-tratados como control
¿Cómo diagnosticar?	<code>bacondecomp Y D, ddetail</code> → mirar peso de "Late vs Early"
¿Cuándo importa?	Peso grande y efectos que cambian con tiempo de exposición
¿Cómo resolver?	<code>csdid</code> → <code>estat simple</code> + <code>csdid_plot</code>
¿Qué es un event study?	δ_k por período relativo: pre = prueba · post = dinámica
¿TWFE o CS en el paper?	Si hay staggered con dinámica → CS. Si efectos constantes → TWFE ok