

Chapter Title: El método de emparejamiento

Book Title: Guía práctica para la evaluación de impacto

Book Subtitle: Guía práctica para la evaluación de impacto

Book Author(s): Raquel Bernal and Ximena Peña

Published by: Universidad de los Andes, Colombia. (2011)

Stable URL: <https://www.jstor.org/stable/10.7440/j.ctt1b3t82z.9>

JSTOR is a not-for-profit service that helps scholars, researchers, and students discover, use, and build upon a wide range of content in a trusted digital archive. We use information technology and tools to increase productivity and facilitate new forms of scholarship. For more information about JSTOR, please contact support@jstor.org.

Your use of the JSTOR archive indicates your acceptance of the Terms & Conditions of Use, available at <https://about.jstor.org/terms>



JSTOR

Universidad de los Andes, Colombia is collaborating with JSTOR to digitize, preserve and extend access to *Guía práctica para la evaluación de impacto*

6

EL MÉTODO DE EMPAREJAMIENTO

Una posible estrategia de identificación es asumir que, dado un conjunto de variables observables X que no están determinadas por el tratamiento (o programa), los resultados potenciales, $Y_i(0)$ y $Y_i(1)$, son *independientes* de la asignación al tratamiento (o programa). Este supuesto implica que todas estas variables que afectan simultáneamente la asignación al tratamiento y los resultados potenciales (Y_i) son observadas por el investigador e incluidas en el modelo que se estima.

Suponga que queremos estimar el impacto de la intervención comparando las variables de resultado del grupo de tratamiento y del grupo de control:

$$E(Y_i(1)|D_i = 1) - E(Y_i(0)|D_i = 0)$$

Sumando y restando el contrafactual, $E(Y_i(0)|D_i = 1)$, tenemos:

$$= E(Y_i(1)|D_i = 1) - E(Y_i(0)|D_i = 1) + E(Y_i(0)|D_i = 1) - E(Y_i(0)|D_i = 0)$$

Los primeros dos términos son el efecto promedio sobre los tratados (*average treatment on the treated*), $\tau^{ATT} = E(Y_i(1)|D_i = 1) - E(Y_i(0)|D_i = 1)$, pues identifican el efecto del programa sobre el grupo de tratamiento menos lo que habría sido la situación del grupo de tratados si no hubieran participado en el programa. Los dos últimos términos miden el sesgo de selección: la diferencia entre el contrafactual y la variable de resultado para el grupo de control.

Es decir, el impacto, estimado como la diferencia en el promedio de las variables de resultado del grupo de tratamiento y del grupo de control, estará compuesto por el efecto verdadero del programa y el sesgo de selección. ¿Cómo separar estos dos componentes? Una posibilidad es

asumir que el sesgo de selección se debe únicamente a diferencias en características observables.

Formalmente, si la selección en el programa se basa únicamente en características observables, se establece que

$$Y(0), Y(1) \perp D | X, \forall X \quad (6.1)$$

y se denomina la *condición de independencia condicional* (CI).

Lo que este supuesto hace es asegurar que al condicionar en las variables observables X , $E(Y_i(0)|D_i = 1, X) = E(Y_i(0)|D_i = 0, X)$ y, por tanto, que el sesgo de selección es igual a cero. Así, calcular el impacto del programa como la diferencia en el promedio de las variables de resultado del grupo de tratamiento y del grupo de control, condicionando en las variables observadas, genera una estimación insesgada del efecto verdadero del programa.

Vale la pena recalcar que el supuesto CI implica que la participación en el programa *no* está determinada por variables no observadas (o no medidas) que también determinen las variables de resultados potenciales (Y_i). Esto excluiría casos en los cuales la decisión de participación en el programa está influenciada por variables no observables o no disponibles en la base de datos, como la habilidad cognitiva innata de los participantes o, en el caso del programa Canasta, la dedicación de la madre a la crianza de sus niños, la mayoría de las cuales no sólo no están contenidas en las encuestas sino que serían muy difíciles de medir, aun si se tuviera esa intención. Por esta razón, el supuesto de CI se considera como fuerte y su incumplimiento puede inducir sesgos en el estimador por emparejamiento.

La versión más sencilla de esta metodología consiste en encontrar un “clon” de cada individuo tratado en el grupo de control y contrastar las variables de resultado de ambos. Donde clon quiere decir un individuo (o grupo de individuos) con exactamente las mismas características observables X , por ejemplo, ingreso, educación, edad, sexo, o cualquier variable que sea pertinente para el programa bajo estudio. Para el caso de Canasta, queríamos emparejar niños según características como edad, sexo, nivel de pobreza, número de hijos en el hogar, nivel educativo del padre y de la madre, entre otras. En general, la metodología se puede entender como una manera de ponderar las observaciones del grupo de control para que la distribución de características observables X sea lo más parecida posible a la del grupo de tratamiento.

Note que la implementación del estimador puede resultar computacionalmente compleja si hay un gran número de variables con base en las cuales estamos emparejando, es decir, si el vector X tiene una dimensión muy grande (la maldición de la dimensionalidad). Una posibilidad, cuando la dimensión de X no es muy grande, es comparar la diferencia en la variable de resultados para cada celda conformada por todos los posibles valores de X .

El efecto del programa es entonces el promedio ponderado de los efectos en cada celda. Este emparejamiento no paramétrico no es práctico si X es de dimensión grande. Cuando el vector X contiene muchas variables, en vez de emparejar con base en un vector de características observadas X , se puede emparejar individuos con base en su probabilidad estimada de participación en el programa, dadas sus características observables $P(X)$, donde

$$P(X) = P(D = 1|X) \quad (6.2)$$

Es decir, el clon adecuado para cada individuo del grupo de tratamiento será aquel del grupo de control con una probabilidad de participación en el programa suficientemente cercana. Todos los estimadores por emparejamiento contrastan la variable de resultado de un individuo tratado con los resultados de uno o más miembros del grupo de control que más se parezcan al individuo tratado, con base en la medida $P(X)$.

La ventaja de emparejar a partir de $P(X)$, a diferencia de X , es que $P(X)$ es un escalar, mientras que X puede tener una dimensión muy grande. Rosenbaum y Rubin (1983) mostraron que si emparejar con base en X genera estimadores consistentes, entonces emparejar con base en $P(X)$ también producirá estimadores consistentes del efecto del programa. La función $P(X)$ se conoce con el nombre de *propensity score* o probabilidad de participación.

Para construir un buen grupo de control es necesario que cualquier combinación de características observadas en el grupo de tratamiento exista también en el grupo de control. Las variables observables de un individuo están resumidas en su probabilidad de participación $P(X)$. Por tanto, un individuo será un control adecuado de un beneficiario del programa si el primero tiene una probabilidad de participar en el programa muy parecida a la del segundo. Esto implica que el método de emparejamiento (*propensity score matching*, PSM) sólo se puede calcular en la región de

soporte común,⁴¹ para asegurar que los grupos de tratamiento y control sean muy parecidos.

La condición de soporte común (SC) establece que individuos con el mismo vector de variables X tienen probabilidad positiva de ser tanto participantes como no participantes en el programa. Es decir, no se pueden utilizar individuos con combinaciones de X tales que exhiben probabilidades positivas de ser participantes pero nulas de ser no participantes (o viceversa). Formalmente, la condición de SC implica que:

$$0 < P(D = 1|X) < 1 \quad (6.3)$$

Si esta condición no se cumple, se podría predecir perfectamente la participación en el programa, es decir, sería posible encontrar una combinación particular de características que predice perfectamente la participación en el programa y, por tanto, no existiría un individuo que fuera un buen control, en el sentido de tener una probabilidad de participación muy parecida.

La condición de SC implica que sólo se utilizan en la estimación individuos del grupo de control que tengan probabilidades de participación $P(X)$ similares a las probabilidades de participación del grupo de tratamiento. Por ejemplo, si existen individuos del grupo de control con probabilidades de participación bajísimas, pero ningún individuo tratado exhibe una probabilidad de participación tan baja, entonces estos individuos del grupo de control se descartarán a la hora de hacer el emparejamiento.

El no cumplimiento de la condición de SC es preocupante cuando hay una fracción importante de individuos tratados para los cuales no existe un individuo de control similar. Es decir, cuando existen individuos tratados con probabilidades de participación que no se encuentran en ningún individuo del grupo de control. Esto implica que existirá un conjunto de individuos para el cual no se puede decir nada acerca del efecto del programa.

Asumiendo que se cumplen las condiciones de CI y SC, el estimador de ATT por PSM estaría dado por:

$$\tau_{ATT}^{PSM} = E_{P(X)|D=1} \{E[Y(1)|D=1, P(X)] - E[Y(0)|D=0, P(X)]\} \quad (6.4)$$

41 El soporte de una variable es el conjunto de valores para los cuales tiene densidad positiva, es decir, el conjunto de valores que pueden ocurrir con alguna probabilidad.

donde $E_{P(X)|D=1}$ es el valor esperado con respecto a la probabilidad de participación $P(X)$, condicional en ser participante del programa. Es decir, un promedio ponderado de las diferencias entre corchetes, donde los ponderadores son funciones de la probabilidad de participación en el programa. El estimador PSM es simplemente la diferencia media en las variables de resultado entre el grupo de tratamiento y el grupo de control en el soporte común, apropiadamente ponderada por la distribución de la probabilidad de participación (o *propensity score*) en el programa de los participantes.

PSM es un método flexible y “oportunista”, pues en principio se puede aplicar al tener una sola observación en el tiempo, siempre que existan observaciones de grupo de tratamiento y control. Por ejemplo, no es necesario contar con información de línea de base. Como PSM se puede aplicar cuando ninguno de los demás métodos no experimentales se puede usar, entonces se utiliza con mucha frecuencia. Por tanto, es necesario tener cuidado de asegurarse de que se cumplen los supuestos para poder aplicar la técnica y, por tanto, dar una interpretación acertada de los resultados. ¿Qué necesitamos en cuanto a los datos para asegurarnos de que PSM funcione? No se puede determinar si se cumplen los supuestos, pues no podemos verificar si lo no observado afecta o no la decisión de participación. Lo que en la práctica se hace es calcular las diferencias en las variables observables X ; si los dos grupos son demasiado diferentes en las características observadas, esto podría ser evidencia de que es probable que también existan diferencias entre los dos grupos en características no observadas.

Los resultados de los métodos de emparejamiento son confiables siempre y cuando existan razones para pensar que las variables no observables o no disponibles en la base de datos, que pueden incluir variables intrínsecamente difíciles de medir, no son un determinante fundamental tanto de la participación en el programa como de las variables de resultado potenciales. Por ejemplo, en un programa en el cual el costo de participación es nulo, es más difícil justificar que unos individuos elegibles participen y otros no, debido a la existencia de diferencias sistemáticas observables entre unos y otros. Si la participación no era costosa, la motivación (variable que usualmente no es posible medir) posiblemente no será un factor importante tanto en la participación del programa como en la determinación de los resultados potenciales.

Una alternativa a PSM sería estimar el modelo de diferencias descrito en el capítulo 4, controlando por todo el vector X de variables independientes

relevantes. De hecho, PSM puede interpretarse como un estimador de mínimos cuadrados ponderado por la probabilidad de participación en el programa. Sin embargo, PSM es preferible al simple modelo de diferencias con regresores adicionales (sección 4.3) por tres razones. Primero, dado que el emparejamiento es un método no paramétrico, no debemos hacer los supuestos implícitos en cuanto a la forma funcional que se hacen al usar las regresiones lineales. Segundo, al restringir la muestra al soporte común aseguramos que estamos comparando grupos comparables (aunque esto puede implicar que los impactos medidos no correspondan al total de la población, sino a una submuestra). Tercero, cuando existen dudas sobre la posibilidad de extrapolación de resultados: si los grupos de tratamiento y control son bastante disímiles, el método de pareo disminuye la extrapolación al reducir la comparación a la región de soporte común.

No existe un método ideal para resolver el sesgo de selección fuera del ámbito experimental. En la práctica, lo mejor que podemos lograr es un método que funcione bajo circunstancias o supuestos que se pueden verificar, y que provea señales de alarma si no está funcionando bien. El método de emparejamiento funciona cuando el sesgo de selección está determinado únicamente por variables observables. Con buenos datos y decisiones acertadas por parte del investigador, PSM puede ser un método poderoso.

En la práctica, la participación en el programa puede depender tanto de variables observables como no observables o no disponibles en la base de datos. Las características de cada programa, en particular su focalización y la respuesta de los agentes, afectan la importancia de las características observables y no observables en la determinación de la selección en el programa. Entonces, para determinar si las variables observadas determinan exclusivamente la participación en el programa, y, por tanto, asegurar que PSM sea una aproximación válida, es necesario estudiar las características particulares del programa en cuestión.

Dada la disponibilidad de datos representativos y altamente comparables para los grupos de tratamiento y control, el proceso de estimación de PSM se puede resumir en el siguiente algoritmo:

1. Estimar la probabilidad de participar en el programa usando las muestras de tratamiento y control.
2. Predecir las probabilidades de participación de cada individuo tanto para los tratados como para los controles.

3. Restringir la muestra al soporte común.
4. Seleccionar un algoritmo de emparejamiento. Para cada individuo tratado se busca un individuo o grupo de individuos de control que tenga una probabilidad de participación similar.
 - Si se encuentran individuos con una probabilidad similar de participación en el programa, siga al paso 6.
 - Si no se encuentran individuos con probabilidad de participación en el programa similar, se vuelve al paso 1 y se especifica nuevamente la ecuación de participación, por ejemplo, incluyendo más interacciones. Si después de varios intentos los indicadores de calidad del emparejamiento no mejoran, esto puede implicar que no se cumple el supuesto de independencia condicional. Por tanto, no es posible estimar los efectos y se debe considerar una estrategia de estimación distinta a PSM.
5. Revisar que las variables observables entre los grupos de tratamiento y control sean parecidas o estén balanceadas (*balancing property*) por grupos de probabilidad predicha. Para realizar esta comparación es necesario conocer las ponderaciones asignadas a los individuos del grupo de control, que están determinadas por el algoritmo de emparejamiento seleccionado.
6. Se calculan los impactos del programa como el promedio apropiadamente ponderado de la diferencia entre la variable de resultado de los tratados y los no tratados.
7. Se calculan los errores estándar e intervalos de confianza para determinar si los impactos son estadísticamente significativos.

A continuación se explica en detalle cada uno de los pasos.

6.1. Probabilidad de participación

Hay dos preguntas fundamentales al estimar la probabilidad de participación: qué modelo usar y qué variables incluir. En cuanto a la selección del modelo, la probabilidad de participación se puede estimar de varias maneras, incluida la probabilidad lineal, probit o logit (ver anexo 4). La idea es especificar un modelo $P(D_i = 1|X) = f(X)$, es decir, la probabilidad de participación como una función $f(\cdot)$ que puede ser lineal o no lineal en las características observables de los individuos, X . Con frecuencia se prefieren logit o probit, y no los modelos de probabilidad lineal, por las

deficiencias de ese último, en particular las predicciones fuera del intervalo $[0, 1]$ y la presencia de heterocedasticidad. Cuando el tratamiento es binario y se estima la probabilidad de participación *vs.* la de no participación, los modelos logit y probit usualmente generan resultados similares. Por tanto, la decisión de qué modelo escoger no es crítica.

Sin embargo, cuando existen varias categorías de tratamiento, el caso es distinto. Un ejemplo de varias categorías de tratamiento es si en Canasta las madres pueden decidir entre recibir un mercado (recomendado por nutricionistas) por valor de \$X al mes, recibir este monto en efectivo para ellas mismas comprar los alimentos, o no participar. Se pueden usar los modelos logit o probit multinomiales. El probit multinomial está basado en supuestos menos fuertes que el logit multinomial y es, por tanto, preferido. En particular, el logit multinomial asume la *independencia de alternativas irrelevantes*, es decir, que la deseabilidad relativa de dos alternativas (*odds ratio*) es independiente de otras alternativas. Este supuesto, aunque conveniente para la estimación, es poco probable que se cumpla en la práctica.

Una vez seleccionado el modelo, ¿qué variables incluir en la estimación de la probabilidad de participación? Heckman, Ichimura, Smith y Todd (1998) muestran que las estimaciones de PSM son muy sensibles a la selección de variables usadas para estimar $P(X)$. La estrategia de emparejamiento se basa en el supuesto de independencia condicional, que implica que las variables de resultado deben ser independientes del tratamiento, una vez se condiciona por la probabilidad de participación. Por tanto, en la estimación de $P(X)$ se deben incluir únicamente variables que afecten la decisión de participación y la variable de resultado de manera simultánea. Los investigadores se pueden guiar por los modelos económicos que describen el fenómeno bajo estudio, investigaciones previas y conocimiento del diseño institucional. Candidatos naturales son entonces variables que no cambien en el tiempo, o aquellas que hayan sido medidas antes de participar en el programa (asegurándose de que el efecto *anticipación* del programa no haya afectado dicha variable).

En el cálculo de la probabilidad de participación se incluye siempre una constante. Si no se tiene claridad acerca de qué variables incluir en la estimación, ¿es mejor incluir más o menos variables? Hay varias razones para evitar incluir demasiadas variables. Por un lado, incluir variables no relacionadas puede exacerbar el problema de soporte común. Por el otro, aunque el incluir variables irrelevantes en la estimación de la participación no sesgará los resultados, ni los hará inconsistentes, sí puede aumentar su varianza. También hay razones que sugieren que no es buena idea

estimar modelos demasiado estilizados. Sólo se debe excluir una variable si hay consenso acerca de que no está relacionada con la variable de resultado o que no es una variable explicativa apropiada (por ejemplo, es una variable que puede verse afectada por el tratamiento).

La decisión de qué variables, interacciones y términos de segundo orden incluir en la estimación de la probabilidad de participación tiene que ver con la significancia estadística. Una alternativa es estimar la especificación preferida y revisar los estadísticos de la estimación para asegurarse del ajuste de ésta. Imbens y Rubin (2010) proponen un algoritmo secuencial para determinar la especificación de la probabilidad de participación, basado en la significancia estadística de cada término. A grandes rasgos, proponen comenzar con una especificación muy parsimoniosa: incluir una constante y las variables que se consideran vitales en el emparejamiento, o que se piensa a priori que están altamente correlacionadas con la variable de resultado. Se define un nivel de significancia esperado para las variables que entren de manera lineal en la especificación. Partiendo del conjunto de variables seleccionadas a priori, se estima repetidamente la probabilidad de participación a través de un probit usando máxima verosimilitud, incluyendo términos adicionales. Se deja el nuevo término sólo si la significancia estadística está por encima del valor predeterminado (usando el estadístico de la prueba de la relación de verosimilitud con la hipótesis nula de que el coeficiente del nuevo término es igual a cero, *likelihood ratio test statistic*). Después de elegir las variables que entran la especificación de manera lineal, se eligen de manera similar uno a uno los términos de segundo orden (cuadráticos e interacciones). Se incluyen términos de segundo orden solamente de las variables incluidas de manera lineal, y se dejan sólo si la significancia estadística está por encima de unos valores predeterminados de nuevo usando el estadístico de la prueba de relación de verosimilitud.

Ejemplo 6.1:

Imagine que inscribirse en el programa Canasta es muy sencillo y cualquiera puede hacerlo con un esfuerzo mínimo. Si una familia que pertenece al Sisbén 1 o 2 quiere participar, sólo tiene que expresarlo; no se exigirá a los beneficiarios que asistan a un control médico sino que la oficina administradora se encarga de entregar el mercado a las familias elegibles. Así, el hecho de que una familia decida no participar puede tener que ver con falta de información –que se puede tomar como algo aleatorio– más que con alguna característica no observable o no disponible en la base de datos. Esto implica que la decisión de participar o no está determinada sobre todo por características obser-

vables, por ejemplo, por el número de hijos en una familia. Así, el método de emparejamiento es una buena alternativa para estimar el impacto de Canasta.

La decisión de participación, para aquellos que finalmente son beneficiarios y no beneficiarios, sería:

$$D_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_K X_{Ki} + u_i$$

donde la variable dependiente, D_i , es una variable binaria igual a 1 si la familia es beneficiaria y a 0 de lo contrario, y X_{1i} a X_{Ki} son características individuales como edad y sexo del niño; del hogar, como la edad, el nivel educativo y ocupación de los padres, estado civil de la madre e ingreso del hogar. En este caso, especificamos un modelo de probabilidad lineal.

Con los coeficientes estimados y las características del hogar, se calcula, para cada hogar de los grupos de tratamiento y control, la probabilidad estimada de participación:

$$\hat{P}(X_i) = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \dots + \hat{\beta}_K X_{Ki}$$

Así, podemos caracterizar a cada familia según su probabilidad de participación en el programa.


6.2. Soporte común

Para estimar el ATT usando PSM necesitamos asegurarnos de que se cumple la condición de SC. Hay varias maneras de hacer esto. La más sencilla e intuitiva es la inspección visual de las distribuciones de densidad de la probabilidad estimada de participación. A manera de ejemplo, dicha comparación se presenta en la gráfica 6.1.

Las dos funciones son distribuciones de la probabilidad de participar para los grupos de control y tratamiento respectivamente. Note que para probabilidades mayores a P_2 no existen observaciones del grupo de control. Esto implica que no podemos encontrar personas en el grupo de control que sean suficientemente parecidas a las de tratamiento, ubicadas después de P_2 , y, por tanto, no tenemos un buen grupo de control para estas observaciones. Así mismo, para valores inferiores a P_1 , no existen observaciones del grupo de tratamiento. Entonces, la región de soporte común está entre P_1 y P_2 y estos puntos de corte se determinan por inspección visual.

Hay otras maneras de determinar el soporte común con más precisión. Una de ellas es el criterio del mínimo y el máximo, que sugiere eliminar las observaciones inferiores al mínimo y mayores que el máximo del otro grupo. Esto se hace tanto para el grupo de tratamiento como para el de control. Estos dos criterios, de inspección visual y del máximo y el mínimo, presentan fallas si hay áreas dentro del soporte común donde no hay observaciones para uno de los dos grupos.

GRÁFICA 6.1. Soporte común



Otra manera de definir la zona de soporte común es elegir los valores de la probabilidad estimada de participación para los cuales hay densidad positiva tanto para el grupo de tratamiento como para el de control. Para asegurarse de que las densidades son estrictamente positivas, también se excluyen regiones que tienen densidad positiva pero muy pequeña. Formalmente, aquellas que no excedan una densidad mínima de q (ver Smith y Todd, 2005). A este criterio se le conoce como *trimming*.⁴²

Mientras más alto sea el porcentaje de individuos emparejados –un parámetro clave de la evaluación– los resultados probablemente estarán calculados con mayor precisión. Independientemente del criterio usado para determinar el soporte común, si la proporción de individuos eliminados es alta, esto genera dudas sobre la posibilidad de generalizar el

42 Después de realizar el *trimming*, es necesario estimar de nuevo a probabilidad de participación.

efecto estimado con los individuos restantes al total de la población. Es decir, se pone en juego la validez externa de las estimaciones.

Ejemplo 6.2:

Imagine que tomamos una submuestra de 10 familias del grupo de tratamiento y 10 del grupo de control de Canasta, con las siguientes probabilidades estimadas de participación:

	1	2	3	4	5	6	7	8	9	10
Tratamiento	0.40	0.48	0.54	0.65	0.75	0.76	0.77	0.8	0.86	0.9
Control	0.21	0.30	0.38	0.42	0.52	0.55	0.59	0.62	0.65	0.77

Si éste fuera el universo de estudio, la zona de soporte común está entre el mínimo del grupo de tratamiento y el máximo del grupo de control. Restringimos entonces el análisis a las familias con probabilidades $\hat{P}(X_i) = \hat{p} \in [0.40, 0.77]$. Los grupos de tratamiento y control restringidos son:

	1	2	3	4	5	6	7
Tratamiento	0.40	0.48	0.54	0.65	0.75	0.76	0.77
Control	0.42	0.52	0.55	0.59	0.62	0.65	0.77

Note que, dada la restricción al soporte común, perdimos tres observaciones del grupo de tratamiento y tres del grupo de control.

Otra manera de restringir el soporte común consiste en tomar las zonas para las cuales existe probabilidad positiva en ambos grupos, es decir, elegir el rango de probabilidades de participación para el cual existen observaciones tanto del grupo de tratamiento como del de control. En este caso, también se eliminan las observaciones con probabilidades menores que 0.4 y mayores que 0.77. Además, note que entre 0.54 y 0.65 no existen observaciones del grupo de tratamiento, y se eliminan además dos observaciones del grupo de control:

	1	2	3	4	5	6	7
Tratamiento	0.40	0.48	0.54	0.65	0.75	0.76	0.77
Control	0.42	0.52	0.55	0.65	0.77		

6.3. Selección de un algoritmo de emparejamiento

La metodología de PSM se puede entender como una manera de ponderar las observaciones del grupo de control para que la distribución de características observables X sea lo más parecida posible a la del grupo

de tratamiento. Todos los estimadores por emparejamiento contrastan la variable de resultado de un individuo tratado los con resultados de uno o más miembros del grupo de control que más se parezcan al individuo tratado, con base en la medida $P(X)$. Sin embargo, los estimadores PSM difieren tanto en la manera en que se encuentra este grupo de individuos de control parecidos al tratamiento, como en la manera como estos vecinos son ponderados a la hora de hacer la comparación. Algunos de los estimadores más usados son el PSM por vecino más cercano (o *NN matching*, por su sigla en inglés, *nearest neighbor*) y el PSM por *kernel*.

a. Estimador PSM por vecino más cercano

Una manera de emparejar cada individuo tratado con el individuo de control “más parecido” consiste en tomar a cada individuo del grupo de tratamiento y buscar un individuo de control con la probabilidad de participación (*propensity score*) más cercana, es decir, el vecino más cercano con base en $P(X)$. Asumiendo que no hay empates, el vecino de control más cercano, $C(i)$, del individuo de tratamiento i está dado por:

$$C(i) = \left\{ j \in D = 0 \mid \arg \min_j \|P_i(X) - P_j(X)\| \right\} \quad (6.5)$$

Es decir, el individuo en el grupo de control tal que la distancia entre su probabilidad predicha de participación y la probabilidad predicha de participación del individuo del grupo de tratamiento sea mínima. El impacto promedio del programa sobre los tratados, usando el estimador de emparejamiento por vecino más cercano, está dado por:

$$\tau_{ATT}^{PSM-VC} = \left\{ \sum_{i=1}^I \text{Promedio} \left((Y_i | D_i = 1) - (Y_{C(i)} | D_i = 0) \right) \right\} \quad (6.6)$$

donde i es un individuo del grupo de tratamiento, I es el número de individuos en el grupo de tratamiento, $(Y_i | D_i = 1)$ es la variable de resultado para el individuo del grupo de tratamiento, $C(i)$ es el conjunto de vecinos más cercanos en el grupo de control del individuo i definido en (6.5) y, por tanto, $(Y_{C(i)} | D_i = 0)$ es la variable de resultado para cada individuo más cercano a i .

Una vez se ha emparejado a cada individuo participante en el programa con uno o más individuos del grupo de control, se computa la diferencia entre la variable de resultado de los individuos de tratamiento y la variable de resultado de los individuos de control. El ATT se obtiene promediando

estas diferencias de forma lineal. Si tomamos sólo al vecino más cercano, el impacto del programa se calcula simplemente como la diferencia entre las variables de resultado.

Si en vez de tomar al individuo con la probabilidad de participación más cercana al tratamiento decidimos tomar a los dos, tres o de manera general los n vecinos más cercanos, se debe decidir cuántos vecinos cercanos elegir para cada observación del grupo de tratamiento y qué peso darle a cada una de estas observaciones al calcular el impacto. La expresión (6.5) entonces se ajusta para tomar a los n vecinos con probabilidades de participación más cercanas a la del individuo de tratamiento, y no solamente a aquellos que minimizan la distancia en la probabilidad predicha de participación.

Para calcular el impacto del programa, se puede dar igual peso a cada uno de los n vecinos cercanos, en cuyo caso en la expresión (6.6) se hace la diferencia entre la variable observada del individuo del grupo de tratamiento y el promedio simple de las variables de resultado para los n vecinos cercanos. Otra alternativa es hacer un promedio ponderado, según qué tan comparable es cada vecino. Es decir, la diferencia entre la variable objetivo del tratamiento con la de cada control se pondera por la distancia en la probabilidad de participar. Así, al impacto medido con un vecino muy cercano se le da más peso que al impacto medido con un vecino no tan cercano.

La decisión de cuántos vecinos más cercanos usar genera una tensión (*trade-off*) entre el sesgo del estimador y su varianza. Al tener más de una observación en el grupo de control el emparejamiento es peor, pues a mayor número de vecinos, estaremos comparando individuos con probabilidades de participación más lejanas y, por tanto, menos “parecidos” entre sí. Esto genera sesgo en las estimaciones. Sin embargo, como se usan más observaciones diferentes para calcular el contrafactual de cada participante, se reduce la varianza.

Este método se puede aplicar con o sin reemplazo. En caso de permitir reemplazo, un individuo del grupo de control puede ser el vecino más cercano para más de un individuo de tratamiento; se usa sólo una vez, en el caso sin reemplazo. Permitir el reemplazo genera de nuevo tensión (*trade-off*) entre el sesgo y la varianza. Al permitir el reemplazo, la calidad promedio del emparejamiento sube y, por tanto, el sesgo disminuye. Pero se reduce el número de individuos *diferentes* que se usan para calcular el contrafactual y, por tanto, las estimaciones son menos precisas. Por lo general, este método se aplica con reemplazo.

En el caso del PSM por vecino más cercano, todos los individuos del grupo de tratamiento en el soporte común son emparejados con algún miembro del grupo de control para el cálculo del ATT. Algunas de estas parejas pueden ser cuestionables, dado que para algunos individuos de tratamiento el vecino más cercano podría tener una probabilidad de participación $P(X)$ bastante distinta,⁴³ y aún contribuir al cálculo del ATT.

b. Emparejamiento de distancia máxima

Si el vecino más cercano es lejano a la observación, el estimador de PSM por vecino más cercano puede emparejar observaciones que no son muy parecidas. Una manera de solucionar esto consiste en imponer un nivel de tolerancia en la distancia entre probabilidades de participación. Emparejar a cada individuo del grupo de tratamiento con la observación más cercana, siempre y cuando la distancia entre las probabilidades de participación sea menor o igual a un número determinado, mejora la calidad del emparejamiento. También se puede emparejar a cada individuo del grupo de tratamiento con *todos* los individuos de control dentro del nivel de tolerancia. Bajo este enfoque, se compara cada observación con tantas parejas como existan dentro del nivel de tolerancia. Así, el grupo de control crece si hay varias parejas cercanas y decrece si no. Por tanto, la comparabilidad de las parejas se asegura y se usa eficientemente la información disponible. Formalmente, se establece el grupo de comparación como:

$$C(i) = \{j \in D = 0 \mid \|P_i(X) - P_j(X)\| \leq k\} \quad (6.7)$$

donde k es la distancia máxima establecida por el investigador. El conjunto de vecinos de control más cercanos, $C(i)$, del individuo de tratamiento i en la anterior expresión tendrá un único elemento bajo el enfoque descrito en el literal a. (o un grupo de elementos si hay empates en observaciones que minimicen la distancia) y contendrá tantos elementos como individuos del grupo de control haya dentro del nivel de tolerancia bajo el enfoque de distancia máxima.

43 Recuerde que el vecino más cercano de un individuo tratado i es aquel que tiene la diferencia en la probabilidad de participación más baja con i que cualquier otro individuo del grupo de control. Esta diferencia, sin embargo, puede no ser lo suficientemente pequeña como para estar seguros de que los dos individuos son muy parecidos, porque en la ecuación (6.5) esta distancia mínima no tiene ninguna restricción de tamaño.

El impacto promedio del programa sobre los tratados tendrá la misma expresión que para el estimador de PSM para el vecino más cercano, (6.6), sustituyendo la definición de conjunto de vecinos de control más cercanos por (6.7). Para calcular el ATT se sigue un procedimiento similar al caso de n vecinos cercanos. Si sólo existe una observación del grupo de control, el impacto del programa sobre ese tratado es la diferencia entre la variable objetivo entre el tratado y el control. Si hay más de un control en la distancia máxima, se hace un promedio (ponderado o no) de las diferencias en la variable objetivo entre el tratamiento y cada uno de los controles.

No es claro, sin embargo, cómo determinar ex ante qué nivel de tolerancia (es decir, qué distancia entre las probabilidades de participación) es razonable.

c. Estimador PSM por estratificación

El estimador de PSM por estratificación (*subclassification* o *blocking* en inglés) hace una partición en el espacio de las probabilidades estimadas, y lo divide en “estratos” o rangos de probabilidad de participación. Luego se calcula el impacto en cada estrato, por ejemplo en el estrato j , como la diferencia promedio en la variable de resultado entre los grupos de tratamiento y control. El ATT se obtiene como la media ponderada de las diferencias por estrato, siendo los pesos la proporción de individuos tratados en el estrato sobre el total de individuos tratados en el soporte común.

$$\tau_{ATT}^{PSM-ESTRATO_j} = \text{Promedio}(Y_i | D=1, j) - \text{Promedio}(Y_{C(i)} | D=0, j) \quad (6.8)$$

¿Cómo determinar cuántos estratos armar? Como se mencionó anteriormente, dentro de cada estrato tanto la probabilidad de participación promedio como la media de las variables de control debe ser igual entre los grupos de tratamiento y control. A esto se le llama que los grupos de tratamiento y control estén balanceados. Si la probabilidad no está balanceada, el intervalo es demasiado grande y es necesario partirlo. Una vez balanceada la probabilidad de participación, es necesario chequear que las variables observadas, X , estén balanceadas también. Si no lo están, es necesario reespecificar la probabilidad de participación, por ejemplo, incluyendo términos de interacción. Basándose en un resultado de Cochran (1968), en la práctica con frecuencia se usan cinco estratos.

Ejemplo 6.3:

Una vez se restringe la muestra al soporte común, comparamos las implicaciones de elegir diferentes métodos de emparejamiento entre observaciones del grupo de tratamiento y control. Usando estos datos ficticios se ejemplificarán los diferentes algoritmos de emparejamiento y, suponiendo que la calidad del emparejamiento es buena, se estimará el ATT.

Volviendo al ejemplo de Canasta, la siguiente tabla contiene información restringida al soporte común tanto de la probabilidad de participación como de la variable resultado, que en este caso es la estatura de las niñas de un año medida en centímetros:

	Observación	1	2	3	4	5	6	7
Tratamiento	Probabilidad de participación: $\hat{p}$	0.40	0.48	0.54	0.65	0.75	0.76	0.77
	Estatura de las niñas de un año: Y_i	69	74	73	74	77	70	80
Control	Probabilidad de participación: $\hat{p}$	0.42	0.52	0.55	0.59	0.62	0.65	0.77
	Estatura de las niñas de un año: Y_i	71	69	70	72	78	70	74

Emparejemos entonces cada una de las observaciones del grupo de tratamiento. La observación de tratamiento con probabilidad de participación 0.40 por vecino más cercano se empareja con el control con probabilidad 0.42, y su contribución al ATT es $69 - 71 = -2$ cm. El tratamiento con probabilidad 0.48 se empareja con el control 0.52 y la contribución es $74 - 69 = 5$ cm. Ya habíamos descrito el emparejamiento del tratamiento 0.54 y su contribución al ATT es $73 - 70 = 3$ cm. El tratamiento con probabilidad 0.65 se empareja con el control 0.62 y la contribución es $74 - 70 = 4$ cm. Los tratamientos con probabilidad 0.75, 0.76 y 0.77 se emparejan con el control 0.77 y las contribuciones son: $77 - 74 = 3$ cm, $70 - 74 = -4$ cm y $80 - 74 = 6$ cm respectivamente. En este caso el ATT es el promedio simple de las contribuciones individuales: $(-2+5+3+4+3-4+6)/7 = 2.1429$.

Si en cambio se usa el algoritmo de tres vecinos más cercanos, el grupo de control de la niña del grupo de tratamiento con probabilidad de participación de 0.54 serían las observaciones con probabilidad de participación 0.52, 0.55 y 0.59. El promedio de la variable de resultado para estas tres observaciones es 70.33. La contribución de este individuo al ATT es:

$73-70.33 = 2.67$ cm; el ATT es, de nuevo, el promedio simple de la contribución de cada observación del grupo de tratamiento.

También se puede usar el emparejamiento de distancia máxima, tomando todas las observaciones cuya distancia no exceda una diferencia en probabilidades de participación de 0.03. Así, el grupo de control para la observación 0.54 tendría dos observaciones (0.52 y 0.55), mientras que la observación de 0.65 del grupo de tratamiento no tendría grupo de control.

Para el emparejamiento por estratificación, suponga que la manera óptima de partir los grupos es en dos estratos, y que el punto de corte es 0.6. En este caso, el impacto en el primer estrato (con probabilidades de participación por debajo de 0.6) es el promedio de la variable resultado entre los tratamientos, menos el promedio en el grupo de control: $72 - 70.5 = 1.5$ cm. En el segundo estrato (con probabilidades de participación por encima de 0.6), el impacto del programa es $75.25 - 74 = 1.25$ cm. El ATT es el promedio del efecto sobre cada estrato ponderado por la proporción de tratados en el soporte común. En este ejemplo los pesos serían $3/7$ para el primer estrato y $4/7$ para el segundo. Es decir, el ATT sería $(1.5 \times 3/7) + (1.25 \times 4/7) = 1.3571$ cm.

La estimación por estratificación es menos sensible a la especificación de la probabilidad de participación dado que estamos volviendo discreta la distribución de los pesos asignados a cada observación. En vez de darle a cada observación un peso igual al inverso de la probabilidad de participación, le asigna el mismo peso a todas las observaciones en un mismo estrato. Otra ventaja de este algoritmo es que, dado que se comparan observaciones dentro del mismo estrato, no se hace extrapolación en los resultados, es decir, no usan los parámetros estimados de una población y se los aplica a otra muy diferente para estimar los impactos.

d. Estimador PSM por kernel y regresión lineal local

Hasta ahora hemos usado información de un subconjunto de los individuos del grupo de control para construir el resultado contrafactual de un individuo tratado. Los PSM por *kernel*⁴⁴ y regresión local lineal (RLL) son estimadores no paramétricos que emparejan a cada individuo del grupo

44 *Kernel* es un procedimiento estadístico que se basa exclusivamente en los datos, sin hacer supuestos paramétricos a priori sobre los modelos económicos. La función de *kernel* pondera los datos del grupo de control, dando más peso a las observaciones con probabilidades de participación cercanas, y menos a aquellas con probabilidades lejanas. En la práctica las funciones *kernel* son continuas por partes (*piecewise continuous*), acotadas, simétricas alrededor de cero, cóncavas en cero y, por conveniencia, generalmente se integran a uno.

de tratamiento con un promedio ponderado de (potencialmente) todos los individuos del grupo de control. Es necesario determinar la vecindad a cada lado de la probabilidad de participación del individuo i que se quiere utilizar para determinar los individuos que se comparan con i . Esta elección es crítica en los métodos de estimación no paramétrica. En principio, con estos estimadores se puede comparar a cada individuo de tratamiento con todos los individuos de control, y darles menos peso en la comparación a aquellos controles con probabilidades de participación más lejanas. Tomar una vecindad más amplia implica un mayor número de observaciones y, por tanto, estimadores que pueden ser más eficientes. Sin embargo, estaremos comparando al individuo de tratamiento con controles que no son muy parecidos a él, de tal manera que el sesgo se incrementa. En la elección de la vecindad hay una tensión entre sesgo potencial del estimador del efecto del programa y su varianza. Si la vecindad es pequeña, se reduce el sesgo porque los individuos son todos más parecidos, pero se aumenta la varianza porque hay pocas observaciones.

En el emparejamiento por *kernel* se compara al individuo tratado i con su respectivo grupo de control, apropiadamente ponderados por una función de qué tan lejos se encuentra cada individuo de control de i con respecto a la probabilidad de participación. Dependiendo de la función de *kernel* que se elija, se estará comparando a cada individuo del grupo de tratamiento con todos los individuos del grupos de control, como es el caso del *kernel* gaussiano o el uniforme, o con un subconjunto de grupo de control, como en el caso de los *kernels* triangular o el Epanechnikov.⁴⁵ El emparejamiento por *kernel* se puede interpretar como una regresión de la variable objetivo del grupo de control en el vecindario de cada observación del grupo de tratamiento sobre un intercepto, usando los pesos del *kernel* (Smith y Todd, 2005). El RLL es esta misma regresión sobre un intercepto, pero se le adiciona un término de pendiente, que es la probabilidad de participación (de allí el nombre de “lineal”, porque se asume que la variable de resultado cambia linealmente con la probabilidad de participación). En ambos casos el intercepto estimado es la contribución de la observación del individuo del grupo de tratamiento al ATT.

El impacto promedio del programa sobre los tratados, usando el estimador de emparejamiento por *kernel* o lineal local, está dado por:

$$\tau_{ATT}^{PSM-KERNEL,RLL} = \frac{1}{I} \left\{ \sum_{i \in D=1} \left[(Y_i) - \sum_{j \in D=0} w_{ij} (Y_j) \right] \right\} \quad (6.9)$$

45 En el ejemplo 6.4 se muestran gráficamente las diferentes funciones de *kernel*.

El impacto promedio se calcula como la diferencia entre la variable objetivo de un individuo del grupo de tratamiento, Y_i , y el promedio ponderado de la variable objetivo en todo el grupo de control, Y_j . I es el número de individuos en el grupo de tratamiento y los pesos de cada observación están dados por el ponderador w_{ij} . En el caso del PSM por *kernel*, el ponderador de cada observación del grupo de control, w_{ij}^{KERNEL} , es una función de qué tan lejos está el individuo del grupo de tratamiento i de cada individuo del grupo de control j :

$$w_{ij}^{KERNEL} = \frac{G\left(\frac{P_i(X) - P_j(X)}{h}\right)}{\sum_{\substack{k=1 \\ k \in D=0}}^K G\left(\frac{P_k(X) - P_i(X)}{h}\right)}$$

donde $G(\cdot)$ es una función de *kernel*, h es el ancho de banda y K es el número de individuos en el grupo de control.⁴⁶ Como se mencionó anteriormente, el *kernel* Gaussiano utiliza todos los individuos del grupo de control para construir la contribución de cada individuo del grupo de tratamiento al ATT. En este caso, el ancho de banda determina el peso relativo de las observaciones lejanas *vs.* cercanas. Los *kernels* triangular y Epanechnikov sólo utilizan algunas observaciones (las más cercanas) del grupo de control. En este caso, el ancho de banda desempeña un doble papel. No sólo determina el peso relativo de las observaciones lejanas *vs.* cercanas, sino que además determina la vecindad a cada lado de la probabilidad de participación que se quiere utilizar para incluir las observaciones del grupo de control en la estimación del contrafactual.

Los pesos usados para calcular el contrafactual contruidos con base en un *kernel* dependen del tipo de *kernel* elegido. Por ejemplo, en el *kernel* uniforme, se les da el mismo peso a todas las observaciones en el grupo de control elegido. Otros *kernels* usados con frecuencia asignan pesos inversamente proporcionales a la distancia entre la probabilidad de participación $P(X)$ de cada individuo del grupo de control y la probabilidad de participación del individuo tratado para el cual se está estimando el contrafactual.

46 El RLL tiene la misma forma que el estimador de *kernel*, pero con una función de ponderación para cada observación, w_{ij}^{RLL} , un poco más compleja (ver, por ejemplo, Blundell y Costa Dias, 2009).

Bajo condiciones estándar del ancho de banda y de la función de *kernel*, el segundo término en el paréntesis en la ecuación (6.9) es un estimador consistente de $E[Y(0)|D=1, P(X)]$, es decir, es un contrafactual válido.

Una ventaja importante de los estimadores de *kernel* y RLL es que tienen menor varianza (que PSM por vecino más cercano, por ejemplo) porque usan más información. RLL, al incluir el término lineal de la probabilidad de participación, aventaja al emparejamiento por *kernel* cuando los controles están distribuidos de manera asimétrica alrededor del tratamiento (por ejemplo, en los extremos de la distribución de $P(X)$). No existe un método para determinar el ancho de banda pero en general éste debe ser menor cuanto mayor sea la muestra.

Ejemplo 6.4:


El estimador de *kernel* empareja a un individuo del grupo de tratamiento con todos los individuos del grupo de control y compara la variable de resultado del tratamiento con un promedio ponderado de las observaciones del grupo de control. La función de *kernel* determina qué ponderación se le da a cada observación del grupo de control, de acuerdo con la distancia entre las observaciones: da más peso a las observaciones con probabilidades de participación cercanas, y menos a aquellas con probabilidades lejanas. En PSM se empareja a los individuos por su probabilidad de participación. Tomemos, en el caso de nuestro ejemplo Canasta, a un individuo en el grupo de tratamiento con probabilidad estimada de participar en el programa de 35%, $P(\hat{D})=0.35$. Dependiendo de la función de *kernel* elegida, el estimador compara a este individuo con todos o con un subconjunto de los individuos en el grupo de control adecuadamente ponderados.

En los ejemplos a continuación, supongamos que queremos asignar pesos positivos a las observaciones en el vecindario de la probabilidad de participación del individuo de tratamiento, es decir, entre $P(\hat{D})+h$ y $P(\hat{D})-h$ con $h=0.01$, y cero a las demás. Comparamos entonces a los individuos en el grupo de tratamiento con probabilidad de participación de 0.35 con los individuos en el grupo de control con probabilidad de participación entre 0.34 y 0.36, es decir, en el conjunto S .

$$S = \left\{ X \in D = 0 \mid P(\hat{X}) \in [0.34, 0.36] \right\}$$

La gráfica 6.2 muestra las observaciones del grupo de control en cuanto a su probabilidad de participación en el programa en el eje X, y de la variable resultado (talla según la edad) en el eje Y.

GRÁFICA 6.2. Individuos en el grupo de control con $P(\hat{D}) \in [0.34, 0.36]$



La función de *kernel* pondera las observaciones del grupo de control de acuerdo con la distancia a la que se encuentran del punto de referencia. Hay varios tipos de funciones de *kernel*. La triangular es la más sencilla, y debe su nombre a la figura geométrica que toman los pesos de las observaciones. La función del *kernel* triangular, $K_{tri}(u_i)$, está dada por:


$$K_{tri}(u_i) = \begin{cases} (1 - u_i) & \text{si } u_i < 1 \\ 0 & \text{si } u_i \geq 1 \end{cases}$$

donde u_i es la distancia relativa de cada observación al punto de referencia $P(\hat{D}) = 0.35$.

$$u_i = \frac{|P(\hat{D}_i) - 0.35|}{h}$$

En este caso particular $h = 0.01$. El resultado de ponderar las observaciones en el grupo de control con la función $K(u_i)$ se puede apreciar en la siguiente gráfica:

GRÁFICA 6.3. Pesos con *kernel* triangular



Como es claro en la gráfica, el *kernel* triangular compara a un tratamiento con un subconjunto del grupo de control. El peso asignado a cada observación del grupo de control es igual a la altura del triángulo en ese punto: cuanto más cerca, mayor peso, y los pesos van disminuyendo de manera lineal. Con base en estos pesos generados se estima el promedio ponderado de las observaciones del grupo de control:

$$\frac{\sum_{j \in S} W_i(Y_i)}{\sum_{j \in S} W_i}$$

donde $W_i(Y_i)$ es el peso que el *kernel* triangular asigna a la variable de resultado de cada observación del grupo de control. En nuestro ejemplo, la variable de resultado para la observación del tratamiento con probabilidad predicha de 0.35 es -1.32, mientras que el promedio ponderado de la variable de resultado para el conjunto S es -1.6; la


diferencia es 0.28. La contribución al ATT de Canasta para un individuo con probabilidad predicha de participación de 0.35 es 0.28. Este procedimiento se repite con todas las observaciones del grupo de tratamiento que se encuentren en el soporte común, y el impacto total del programa será un promedio simple de los impactos sobre cada individuo del grupo de tratamiento.

Además del triangular, hay otros tipos de funciones de *kernel* frecuentemente utilizadas, como el gaussiano y el Epanechnikov. El *kernel* gaussiano, $K_{\text{gaus}}(u_i)$, pondera las observaciones generando una función de densidad normal alrededor del punto de referencia:

$$K_{\text{gaus}}(u_i) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u_i^2}$$

Gráficamente el resultado es el siguiente:

GRÁFICA 6.4. Pesos con *kernel* gaussiano




Aunque no se vea claramente en el gráfico, el *kernel* gaussiano da peso positivo a todas las observaciones.

Por otro lado, el *kernel* Epanechnikov, $K_{\text{epa}}(u_i)$, se construye de la siguiente manera:

$$K_{\text{epa}}(u_i) = \begin{cases} \frac{3}{4}(1-u_i^2) & \text{si } u_i < 1 \\ 0 & \text{si } u_i \geq 1 \end{cases}$$

Gráficamente el *kernel* Epanechnikov se ve así:

GRÁFICA 6.5 Pesos con *kernel* Epanechnikov



e. Estimador de dobles diferencias emparejadas

Una de las ventajas del método de emparejamiento es que se puede aplicar a un único levantamiento de información, siempre y cuando existan observaciones de tratamientos y controles. Sin embargo, si hay información longitudinal, o cortes transversales repetidos, se pueden combinar los métodos de emparejamiento con el de diferencias-en-diferencias, de tal manera que se relajan los supuestos de cada uno de estos métodos, y, por tanto, los resultados se vuelven más robustos. En adelante, supondremos que contamos con información longitudinal, para facilitar la exposición.⁴⁷ Recuerde que el PSM asume que la selección en el programa se basa única y exclusivamente en características observables de los individuos. Al contar con información longitudinal y combinar PSM con diferencias-en-diferencias, la selección en el programa puede también depender de variables no observables, siempre y cuando éstas permanezcan constantes en el tiempo.

⁴⁷ El caso de tener información de cortes transversales repetidos es similar en la aproximación, pero tiene un mayor nivel de complejidad técnica. Se refiere al lector interesado a Blundell y Costa Dias (2009).

Se cuenta con información de (al menos) dos períodos, t_1 y t_2 , donde $t = 1$ es el período anterior a la implementación del tratamiento, comúnmente conocido como la línea de base, y $t = 2$ es el período posterior a la implementación del tratamiento o período de seguimiento. La condición de independencia condicional en este contexto se redefine como el supuesto de que la *evolución* de los no observables es independiente del tratamiento, al controlar por

$$u_{i2} - u_{i1} \perp D | X, \forall X$$

El subíndice de u indica el período al que corresponde esa observación. Por ejemplo, u_{i1} corresponde a la observación de u en el período anterior al experimento. Esta versión de independencia condicional implica que los tratamientos y controles habrían evolucionado de la misma manera si ninguno de los dos hubiera sido objeto del tratamiento. Es decir, la variable objetivo para ambos grupos sigue una tendencia común.

Dado que estamos combinando emparejamiento con diferencias-en-diferencias, necesitamos de nuevo restringir al soporte común para asegurar que los grupos de tratamiento y control sean muy parecidos, y así lograr identificar el ATT. De nuevo, la condición de soporte común (SC) establece que individuos con el mismo vector de variables X tienen probabilidad positiva de ser tanto participantes como no participantes en el programa. Puesto que contamos con datos longitudinales, la condición es idéntica al caso base de emparejamiento:

$$0 < P(D = 1 | X) < 1 \quad (6.10)$$

Asumiendo que se cumplen las condiciones de CI y SC, el estimador de ATT de *dobles diferencias emparejadas* (DDE), en la región de soporte común, estaría dado por:

$$\tau_{ATT}^{DDE} = E_{P(X)|D=1} \{E[Y_2(1) - Y_1(1) | D = 1, P(X)] - E[Y_2(0) - Y_1(0) | D = 0, P(X)]\} \quad (6.11)$$

donde $E_{P(X)|D=1}$ es el valor esperado con respecto a la probabilidad de participación, condicional en ser participante del programa. El subíndice de Y indica el período al que corresponde esa observación de la variable de resultado. Por ejemplo, Y_1 corresponde a la observación de Y en el período anterior al tratamiento. Finalmente, la condición $\cdot | D$ indica si la observa-

ción corresponde a un individuo del grupo de tratamiento ($D = 1$) o a un individuo del grupo de control ($D = 0$).

El estimador de DDE es la diferencia media en las variables de resultado antes y después de la intervención, entre el grupo de tratamiento y el grupo de control en el soporte común, apropiadamente ponderada por la distribución de la probabilidad de participación en el programa de los participantes.

f. ¿Qué algoritmo de emparejamiento elegir?

En muestras grandes, asintóticamente todos los algoritmos de emparejamiento deben generar los mismos resultados, puesto que tienden a comparar sólo parejas idénticas. En muestras pequeñas, sin embargo, la selección de algoritmo puede afectar los resultados estimados, pues con frecuencia existe una tensión entre dos objetivos deseables: tener un estimador insesgado y minimizar la varianza. La selección del estimador depende de las características de cada caso, pues ningún algoritmo es siempre mejor que los demás. Es mejor, entonces, ser pragmáticos e intentar diversos algoritmos. Si los resultados son muy similares, entonces la selección del algoritmo es poco importante. Pero si los resultados difieren, es necesario determinar qué genera la disparidad, antes de elegir un algoritmo (Bryson, Dorsett y Purdon, 2002).

Todos los métodos de emparejamiento descritos anteriormente se pueden entender como una asignación de pesos para promediar las observaciones de los individuos de control, de tal manera que el grupo de control sea idéntico al grupo de tratamiento. Estos mismos pesos se utilizan para calcular la calidad del emparejamiento, como se describe en la siguiente sección.

6.4. Calidad del emparejamiento

Como el emparejamiento no se hace condicional en todas las variables observadas sino únicamente en la probabilidad de participación, es necesario determinar si el emparejamiento balancea la distribución de las variables relevantes entre los grupos de tratamiento y control. Para que PSM funcione, condicional en la probabilidad de participación, los grupos de tratamiento y control deben ser similares o estar balanceados. Esto implica que tanto la probabilidad de participación promedio como las medias de las variables contenidas en el vector X sean idénticas entre los grupos de tratamiento y control. Así, se quiere determinar si después de

condicionar por la probabilidad de participación aún existen diferencias en las características observables entre los grupos de tratamiento y control. Note que este análisis se realiza usando únicamente información de las variables de control, y no las de resultado, y por tanto hacen parte de la etapa de diseño. Sin embargo, se presentan después de la elección del método de emparejamiento pues para realizar los ejercicios que permitirán determinar la calidad del emparejamiento necesitamos los pesos (*weights*) para ponderar las variables del grupo de control; estos pesos dependen del método de emparejamiento.

¿Cómo evaluar si el emparejamiento fue bueno? Intuitivamente, después de controlar por el efecto de la probabilidad de participación, condicionar en las variables observables no debe generar nueva información acerca del tratamiento. Podemos entonces estimar la siguiente ecuación por MCO:

$$D_i = \beta_0 + \beta_1 \hat{P}(X_i) + \gamma_1 X_{i1} \dots + \gamma_K X_{Ki} + u_i \quad (6.12)$$

donde $X_{i1}, \dots, X_{Ki}$ son K características individuales. Cuando el tratamiento, después de controlar por $\hat{P}(X)$, no está correlacionado con las características individuales, los coeficientes que acompañan las variables observables, γ_1 a γ_K , no deben ser estadísticamente diferentes de cero. Si los coeficientes que acompañan las X_{ki} son distintos de cero, esto sugiere, o bien una mala especificación del modelo usado para calcular $P(X)$, o bien que no se cumple el supuesto de CI.

Se pueden calcular estadísticos t en las muestras de tratamiento y control para determinar si hay diferencias significativas en el promedio de las variables de control entre los grupos de tratamiento y control. Las variables del grupo de control deben estar apropiadamente ponderadas por los pesos, que dependen del método de emparejamiento. Es de esperar que haya diferencias antes del emparejamiento, pero después de éste la distribución de variables observables debe estar balanceada entre los dos grupos y no debe haber diferencias estadísticamente significativas.

Otra manera de determinar la calidad del emparejamiento consiste en usar la idea de estratificación: se divide el espacio de las probabilidades estimadas de los grupos de tratamiento y control en “estratos” o rangos de probabilidad de participación. Los estratos se eligen de tal manera que esté balanceada la probabilidad de participación entre ellos, es decir, que sea igual el promedio de la probabilidad de participación estimada de los

grupos de tratamiento y control. Luego, se usan estadísticos t dentro de cada estrato para determinar si los primeros dos momentos de la distribución de las variables en X son idénticos entre grupos. Si la muestra está balanceada, se prosigue con el cálculo del impacto del programa, descrito en la sección de selección del algoritmo de emparejamiento. De lo contrario, es necesario reestimar la probabilidad de participación incluyendo términos que añadan flexibilidad, como términos cuadráticos o cúbicos, interacciones o diferentes variables en la estimación de la probabilidad de participación, hasta que estas diferencias desaparezcan.

6.5. Errores estándar

Una vez calculamos el ATT, es necesario calcular los errores estándar y con ellos los intervalos de confianza de las estimaciones, para determinar si el impacto del programa es estadísticamente significativo. Una de las desventajas del PSM es que calcular los errores estándar no es fácil, pues deben incorporar la varianza debida a la estimación de la probabilidad de participación. Si el emparejamiento se hizo sin reemplazo, también se debe incluir la varianza asociada a este método de emparejamiento. Los errores estándar, en este caso de los estimadores de PSM, se pueden calcular de dos maneras. Por un lado, se pueden calcular analíticamente, es decir, encontrando una expresión explícita de la varianza. Por ejemplo, al usar el método de vecino más cercano, es posible calcular los errores de manera analítica.

Sin embargo, cuando las fórmulas para la varianza son tan complicadas que no se conoce la distribución asintótica del estimador, ni se tiene una fórmula para el cálculo de errores estándar, los errores se pueden calcular usando *bootstrapping*. Éste es el caso, por ejemplo, del PSM por *kernel*. El *bootstrapping* consiste en estimar propiedades de un estimador, por ejemplo, su varianza, midiendo dichas propiedades en la distribución empírica de los datos. Cuando se puede asumir que las observaciones vienen de una población independiente e idénticamente distribuida, el *bootstrapping* se puede implementar construyendo una serie de muestras (con reemplazo) proveniente de la base de datos original. El cálculo de los errores estándar por ambos métodos debe generar resultados similares.

Abadie e Imbens (2008) muestran que el *bootstrapping* no funciona para los estimadores de n vecinos cercanos, ya que en este caso no genera bandas de confianza asintóticamente válidas. Por tanto, para el estimador de n vecinos cercanos se sugiere calcular los errores estándar de manera analítica.

6.6. Pruebas de falsificación

El supuesto de independencia condicional, condición (6.1), permite la identificación de los impactos de interés en el método de pareo. Lo que este supuesto implica es que la selección depende únicamente de variables observables. Por tanto, para eliminar el sesgo de selección es suficiente controlar por el conjunto de variables observables relevantes.

El supuesto de independencia condicional, sin embargo, no tiene implicaciones que se puedan comprobar directamente en los datos y, por tanto, no es posible determinar de manera directa si se cumple o no. Sin embargo, es posible realizar algunos ejercicios para evaluar si la estrategia de identificación tiene validez, comúnmente llamados pruebas de falsificación.

Imbens y Rubin (2010) sugieren dos tipos de pruebas de falsificación: 1) estimar el efecto del programa sobre una variable de resultado ficticia, de la cual tenemos la seguridad de que no puede ser afectada por el tratamiento (pseudoresultado) y 2) estimar el efecto causal de una intervención ficticia que se sabe no debería tener efectos sobre nuestra variable de resultado (pseudotratamiento).

La primera prueba de falsificación consiste en estimar el efecto causal de la variable de tratamiento sobre una variable que claramente no puede haber sido afectada por éste, o pseudoresultado. Típicamente, se eligen las variables de resultado rezagadas, medidas en uno o más períodos de tiempo anteriores a la intervención. La selección de cuál variable es adecuada para hacer la prueba de falsificación es específica al contexto. Por ejemplo, si nos interesa el efecto de un programa de entrenamiento laboral en el período t sobre los ingresos futuros Y_{t+1} , una prueba de falsificación podría ser estimar el efecto del entrenamiento sobre los ingresos de los individuos dos años antes de entrar al programa (Y_{t-2})⁴⁸ controlando por todo el historial anterior de ingresos que tengamos disponible (Y_{t-3}, Y_{t-4} , etc.). Note que una vez se controla por este historial de ingresos pasados, la intervención en t no debería tener efectos sobre Y_{t-2} . Si no se controla apropiadamente por el historial de ingresos, es posible que sí se encuentre un efecto de la intervención sobre los ingresos rezagados Y_{t-2} , simplemente porque estaría capturando trayectorias de ingresos sistemáticamente diferentes entre individuos participantes e individuos

48 En la evaluación de algunos programas de entrenamiento se ha encontrado que los ingresos de los participantes sufren una caída en el período antes de iniciar el entrenamiento (Y_{t-1}). A esto se le conoce como "*Ashenfelter's dip*". Por tanto, en el texto elegimos el ingreso rezagado dos períodos.

no participantes que, a su vez, determinaron que unos participaran en el programa y otros no.

Por otra parte, si se encuentra que la intervención no tiene efectos sobre $Y_{t-2'}$ controlando por el historial de ingresos, es plausible que se cumpla el supuesto de selección en observables. Si la intervención sí afecta $Y_{t-2'}$, entonces esto sería evidencia que sugiere que no se cumple el supuesto de selección por características observables y, por tanto, el método de emparejamiento no sería adecuado para estimar el impacto del programa de entrenamiento. Note que al igual que la evaluación de la calidad del emparejamiento, esta primera prueba de falsificación se realiza usando únicamente información de las variables de control y no las de resultado.

Si la prueba de falsificación falla, el emparejamiento no es un buen método para calcular el impacto pues la selección seguramente no se da sólo en características observables. Sin embargo, esta prueba desafortunadamente no genera sugerencias acerca de qué métodos serían más adecuados. Seguramente se tendrían que usar métodos que controlen por el sesgo de selección debido a variables observables y también a variables no observables o no disponibles en los datos, tales como variables instrumentales, regresión discontinua o los demás descritos en los capítulos posteriores.

Ejemplo 6.5:

Imagine que queremos evaluar el impacto de Canasta sobre el estado nutricional de los niños medido por el peso según la edad. Es decir, el impacto del programa se mide como la diferencia en el peso según la edad de los niños del grupo de tratamiento y los de control después de implementado el programa. Suponga que el método elegido para calcular el impacto es emparejamiento por estratificación.

Una manera de determinar si la estrategia de identificación tiene validez es hacer el primer tipo de prueba de falsificación. Se toman los mismos grupos de tratamiento y control y el mismo método de estimación. Sin embargo, en vez de estimar el efecto sobre el peso según la edad *después* del programa, se estima sobre el peso al nacer. Como el peso al nacer es una variable que precede al tratamiento, no debería verse afectada por éste. Es importante que en esta prueba de falsificación se incluyan otras variables de control observadas que sí determinan el peso al nacer como, por ejemplo, la educación de la madre y los ingresos del hogar; variables que a su vez podrían también determinar la participación en el programa. Si no se controla por estas características entonces la intervención sí podría resultar significativa para

explicar el peso al nacer simplemente porque los individuos tratados y los individuos de control son diferentes precisamente en características como la educación y los ingresos del hogar.

Aunque los cálculos no evalúan directamente el supuesto de identificación, generan información valiosa acerca de si el razonable pensar que se cumple. Si las estimaciones sugieren que Canasta, como era de esperarse, no tiene efecto sobre el peso al nacer, entonces es plausible que se cumpla el supuesto de independencia condicional. Si en cambio, las estimaciones sugieren que Canasta sí tiene efecto sobre el peso al nacer, estamos encontrando un efecto espurio que viola el supuesto de independencia condicional. En este caso, el método de emparejamiento no es adecuado para estimar el impacto de Canasta.

La segunda prueba de falsificación tiene que ver con estimar el efecto causal de una intervención “ficticia” que se sabe que no tiene efectos, o pseudotratamiento. Para esto necesitaríamos, por ejemplo, tener información de múltiples grupos de control. Por ejemplo, para estimar los efectos de un programa de entrenamiento para una ciudad en particular, podemos tener dos grupos de control. El primero está compuesto por individuos elegibles (vivían en la ciudad) pero decidieron no tomar el entrenamiento (control a). El segundo está compuesto por aquellos que vivían justo por fuera del límite de la ciudad, y por tanto no eran elegibles para beneficiarse del tratamiento, pero que en otras dimensiones eran comparables a los beneficiarios (control b). En este caso estimaríamos el impacto del pseudotratamiento “pertenecer al grupo de control a” con respecto al grupo de comparación “pertenecer al grupo de control b” sobre los ingresos en el período posterior al entrenamiento. Sabemos que este pseudotratamiento no debe tener impacto alguno. Si los cálculos sugieren que el pseudotratamiento no tiene efectos, es plausible que se cumpla el supuesto de selección en observables. Si no, el método de emparejamiento no es adecuado para estimar el impacto del programa.

Estas pruebas de falsificación deberían hacer parte de la etapa de diseño. Este análisis debe realizarse incluso antes de calcular los impactos del programa. Si los análisis sugieren que la estrategia de identificación no es creíble, esto implica que el aplicar la metodología propuesta no tiene sentido pues no estaremos identificando el impacto deseado. Las pruebas, sin embargo, no sugieren qué camino tomar; sólo hacen explícito que el método elegido no es apropiado para estudiar los impactos, ya que no se cumplen los supuestos de identificación. Las pruebas de falsificación se pueden realizar no sólo en el contexto de emparejamiento, sino también para los métodos discutidos en varios de los capítulos posteriores.

6.7. Implementación del método de emparejamiento en Stata

En el ejemplo práctico que se utiliza en este libro acerca del programa Canasta se evalúa el efecto de la intervención sobre la estatura según la edad de los niños participantes. Para realizar la estimación del efecto del programa usando métodos de emparejamiento, primero se debe estimar la probabilidad de participación en el programa o *propensity score*. Dado que la variable dependiente, participación, es una variable binaria, esta decisión se puede estimar usando el modelo de probabilidad lineal o los modelos logit o probit (ver anexo 4). Los resultados presentados a continuación muestran precisamente los efectos marginales calculados por medio de un probit.

Primero se debe determinar qué variables incluir en la estimación de la decisión de participación. Es importante no omitir ninguna variable ni sobreespecificar el modelo; por lo tanto, se debe ser cuidadoso en el momento de decidir qué variables incluir. Se incluyen en la estimación únicamente aquellas que son significativas al 95% de confianza.

El resultado 6.1 muestra el modelo elegido para generar las probabilidades predichas de participación en el programa o *propensity score*. Note que todas las variables incluidas son altamente significativas, y que además el modelo es significativo en su conjunto. Con los coeficientes estimados se predice la probabilidad de participación en el programa tanto para el grupo de tratamiento como para el de control. Es útil ver las distribuciones de la probabilidad predicha para ambos grupos usando histogramas, como los que se presentan en el resultado 6.2 donde 0 representa el grupo de control y 1 el grupo de tratamiento.

Gráficamente vemos que las probabilidades predichas son similares entre los grupos de tratamiento y control. Sin embargo, hay probabilidades de participación en el grupo de tratamiento superiores a la máxima probabilidad del grupo de control y, de la misma manera, probabilidades en el grupo de control inferiores a la mínima probabilidad del grupo de tratamiento. Por tanto, para asegurarse de comparar individuos comparables, se restringe la muestra al soporte común.


La restricción de la muestra al soporte común se puede hacer visualmente, lo que en este caso implica eliminar las observaciones del grupo de tratamiento que están por encima de la máxima observación del grupo de control, y eliminar las observaciones del grupo de control que se encuentran por debajo de la observación mínima del grupo de tratamiento.

participación para los grupos de tratamiento y control. Los resultados de la estimación del comando `pscore` para el caso de Canasta se presentan en el resultado 6.3.


Resultado 6.2:

```
predict pscore
(option pr assumed; Pr(D))
```

Histograma de las probabilidades predichas
`histogram pscore, by(D)`



Histograma del *propensity score* para los grupos de tratamiento y control



Resultado 6.3:

Los resultados presentados en este recuadro son una versión resumida de la salida de Stata. Se presentan sólo unos resultados descriptivos de lo que es la salida completa.

```
. global X "personas orden_n ocupado_jefe educa_jefe ingresos_hogar_jefe"
. pscore D $X, pscore(pscore_b) blockid(id) comsup det
```

```
*****
```

Algorithm to estimate the propensity score

```
*****
```

The treatment is D

D	Freq.	Percent	Cum.
0	2,048	51.20	51.20
1	1,952	48.80	100.00
Total	4,000	100.00	

Estimation of the propensity score

Iteration 0: log likelihood = -2771.4366

Iteration 1: log likelihood = -2739.6891

Iteration 2: log likelihood = -2739.6749

Probit regression

	Number of obs = 4000
	LR chi2(5) = 63.52
	Prob > chi2 = 0.0000
Log likelihood = -2739.6749	Pseudo R2 = 0.0115

D	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
personas	-.0547807	.0107191	-5.11	0.000	-.0757897 -.0337717
orden_n	.2290269	.0618843	3.70	0.000	.1077359 .3503178
ocupado_jefe	.2053767	.0522936	3.93	0.000	.102883 .3078703
educa_jefe	-.0151349	.00544	-2.78	0.005	-.0257972 -.0044727
ingresos_h-e	.0007741	.0002392	3.24	0.001	.0003054 .0012429
_cons	-.1307518	.104657	-1.25	0.212	-.3358758 .0743721

Note: the common support option has been selected

The region of common support is [.25222035, .75646462]

```
*****
```

Step 1: Identification of the optimal number of blocks

Use option detail if you want more detailed output

```
*****
```

Distribution of treated and controls across blocks

Blocks of				
the pscore				
for				
treatment				
D	D			
o	0	1	Total	
-----+-----				
2	207	137	344	
3	1,799	1,723	3,522	
4	39	92	131	
-----+-----				
Total	2,045	1,952	3,997	

Test that the mean propensity score is not different for treated and controls

Test in block 2

Observations in block 2

obs: 344, control: 207, treated: 137

Test for block 2

Two-sample t test with equal variances

Group	Obs	Mean	Std. Err.	Std. Dev.	[95% Conf. Interval]	
-----+-----						
0	207	.3631226	.0024041	.0345893	.3583828	.3678624
1	137	.3667202	.0025609	.0299742	.361656	.3717845
-----+-----						
combined	344	.3645554	.0017701	.0328313	.3610737	.3680371
-----+-----						
diff		-.0035976	.003616		-.01071	.0035148
-----+-----						

diff = mean(0) - mean(1)

t = -0.9949

Ho: diff = 0

degrees of freedom = 342

Ha: diff < 0

Ha: diff != 0

Ha: diff > 0

Pr(T < t) = 0.1602

Pr(|T| > |t|) = 0.3205

Pr(T > t) = 0.8398

The mean propensity score is not different for
treated and controls in block 2

The final number of blocks is 8

This number of blocks ensures that the mean propensity score
is not different for treated and controls in each blocks

Step 2: Test of balancing property of the propensity score
Use option detail if you want more detailed output

Testing the balancing property in block 2

obs: 344, control: 207, treated: 137

Testing the balancing property for variable personas in block 2

Two-sample t test with equal variances

Group	Obs	Mean	Std. Err.	Std. Dev.	[95% Conf. Interval]	
0	207	8.05314	.1940931	2.792514	7.670476	8.435804
1	137	8.167883	.2233112	2.613791	7.726272	8.609495
combined	344	8.098837	.1466233	2.719458	7.810443	8.387231
diff		-.1147431	.2998867		-.7045976	.4751114
diff = mean(0) - mean(1)				t = -0.3826		

Ho: diff = 0

degrees of freedom = 342

Ha: diff < 0	Ha: diff != 0	Ha: diff > 0
Pr(T < t) = 0.3511	Pr(T > t) = 0.7022	Pr(T > t) = 0.6489

Variable personas is balanced in block 2

The balancing property is satisfied


-This table shows the inferior bound, the number of treated and the number of controls for each block

Inferior	d		Total
of block	0	1	
of pscore			
.2	207	137	344
.4	356	226	582
.45	141	88	229
.4625	133	143	276
.475	371	394	765
.5	798	872	1,670
.6	39	92	131
Total	2,045	1,952	3,997

Note: the common support option has been selected

End of the algorithm to estimate the pscore

Histograma del *propensity score* para los grupos de tratamiento y control



D = indicador de participación en el programa

Personas = tamaño del hogar

orden_n = orden de nacimiento del niño

ocupado_jefe = indicador igual a 1 si el jefe de hogar trabaja

educa_jefe = años de escolaridad del jefe de hogar

ingresos_hogar_jefe = ingresos del jefe del hogar en decenas de miles de pesos

En el resultado 6.3 se presentan unos resultados descriptivos, mas no completos, del comando `pscore`. Bajo el título “Algorithm to estimate the propensity score”, se presentan primero unas estadísticas descriptivas de participación en el programa, y luego el modelo de participación estimado por probit. En el “Step 1: Identification of the optimal number of blocks” se determina el número óptimo de estratos, comparando el promedio de la probabilidad de participación predicha entre los grupos de tratamiento y control para cada bloque. En la sección “Step 2: Test of balancing property of the propensity score” se verifica que el promedio de las variables de control sea idéntico entre los grupos de tratamiento y control en cada estrato. Finalmente, para hacer una inspección visual, se presenta el histograma de la probabilidad de participación para los grupos de tratamiento y control.

Otra manera de verificar la calidad del emparejamiento consiste en estimar el modelo probit de la probabilidad de participación como función de las características observadas escogidas, controlando también por la probabilidad predicha. Si el emparejamiento fue exitoso y estamos comparando grupos comparables, los coeficientes asociados a las características de los individuos no deben ser estadísticamente significativos.

Resultado 6.4:

```
. dprobit D pscore $X

Iteration 0: log likelihood = -2771.4366
Iteration 1: log likelihood = -2739.7035
Iteration 2: log likelihood = -2739.6749
Iteration 3: log likelihood = -2739.6749

Probit regression, reporting marginal effects      Number of obs =   4000
LR chi2(6)      =  63.52
Prob > chi2     = 0.0000
Pseudo R2      = 0.0115

Log likelihood = -2739.6749

-----+-----
      D |      dF/dx   Std. Err.   z     P>|z|   x-bar   [95% C.I.]
-----+-----
      pscore | -.0722039   6.66442  -0.01   0.991   .488018  -13.1342  12.9898
personas | -.023386   .1423828  -0.16   0.870   5.04525  -.302451  .255679
orden_n | .0978192   .5998446   0.16   0.870   1.10675  -1.07785  1.27349
ocupad~e* | .087163   .5290167   0.16   0.871   .809    -.949691  1.12402
educa~e | -.0064631   .039564  -0.16   0.870   6.57575  -.084007  .071081
ingres~e | .0003303   .0019992   0.17   0.869   72.9454  -.003588  .004249
-----+-----

      obs. P |      .488
      pred. P | .4878079(at x-bar)
-----+-----

(*) dF/dx is for discrete change of dummy variable from 0 to 1
    z and P>|z| correspond to the test of the underlying coefficient being 0

D = indicador de participación en el programa
pscore = probabilidad de participación en el programa
personas = tamaño del hogar
orden_n = orden de nacimiento del niño
ocupado_jefe = indicador igual a 1 si el jefe de hogar trabaja
educa_jefe = años de escolaridad del jefe de hogar
ingresos_hogar_jefe = ingresos del jefe del hogar en decenas de miles de pesos
```

El resultado 6.4 presenta la estimación de un modelo probit con el índice de tratamiento como variable dependiente, y como independientes, la probabilidad de participación y todas las variables explicativas inclui-

das en la ecuación de selección (o modelo de participación). El emparejamiento es bueno ya que, una vez se controla por la probabilidad de participación, las demás variables no resultan significativas para explicar el tratamiento. Para confirmar este análisis se puede realizar un test de significancia conjunta de las demás variables. Si las demás variables no resultan ser significativas en su conjunto, la probabilidad de participación es una estadística suficiente de la decisión de participar.

Existe un comando que realiza todos los pasos descritos hasta ahora de manera automática: `psmatch2`. Este comando calcula la probabilidad de participación, o permite que se determine la variable que calcula la probabilidad de participación; por ejemplo, si se ha calculado con anterioridad la probabilidad de participación usando el comando `pscore`, se puede definir en `psmatch2` la opción de usar la probabilidad predicha de esa estimación. También se asegura el restringir al soporte común, y que el emparejamiento sea de buena calidad. Además, `psmatch2` permite elegir entre varios métodos de emparejamiento, incluidos vecinos más cercanos, distancia máxima, *kernel* y emparejamiento lineal local. Para todos los métodos de emparejamiento, el comando `psmatch2` calcula los errores estándar por medio de *bootstrapping*.

Al utilizar el método de vecino más cercano, el programa `psmatch2` empareja a un individuo del grupo de tratamiento con el individuo del grupo de control que tiene una probabilidad más cercana de participación en el programa. Sin embargo, cuando se presentan casos en los que hay varios individuos en el grupo de control a la misma distancia de un solo individuo de tratamiento, debemos asegurarnos de que el orden en el que se presentan los datos en nuestra base sea aleatorio, pues el orden podría, en principio, afectar los resultados. Por tanto, antes de ejecutar el comando `psmatch2`, hay que aleatorizar el orden de los datos, por ejemplo:

```
. set seed 50
. drawnorm orden
. sort orden
```

Para replicar los resultados obtenidos se especifica una semilla en el proceso de aleatorización. En el resultado 6.5 la nota después de la estimación de la probabilidad de participación, "There are observations with identical propensity score values. The sort order of the data could affect your results. Make sure that the sort order is random before calling `psmatch2`.", se refiere a este caso de empate en la mínima distancia al individuo del grupo de tratamiento.

En el resultado 6.5 se muestra el impacto del programa con emparejamiento del vecino más cercano, especificando el soporte común mediante recorte (*trimming*). Primero, `psmatch2` estima la probabilidad de participación mediante un *probit*. A través del *commando* `psmatch2`, al elegir la opción de *trimming*, Stata impone la condición de soporte común al eliminar un porcentaje determinado de observaciones (20% en el ejemplo) que corresponden a rangos de la probabilidad de participación que tienen la más baja densidad en la probabilidad de participación. Luego calcula el impacto del programa, o ATT, como la diferencia promedio en la variable de interés entre cada individuo del grupo de tratamiento y su vecino más cercano. En este caso, el impacto estimado del programa en el soporte común es de 0.35 desviaciones estándar, lo cual es un efecto significativo al 1% de confianza.

El resultado 6.6 presenta el impacto estimado del programa usando el emparejamiento de *kernel* y el soporte común predeterminado del comando, es decir, eliminación de mínimo y máximo (ver sección 6.2): 0.32 desviaciones estándar, significativo a 1% de confianza.

Resultado 6.5:

```
. psmatch2 D $X, outcome(ha_nchs2) n(1) trim(20)
```

Probit regression	Number of obs = 4000
	LR chi2(5) = 63.52
	Prob > chi2 = 0.0000
Log likelihood = -2739.6749	Pseudo R2 = 0.0115

	D	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
-----+-----						
personas		-.0547807	.0107191	-5.11	0.000	-.0757897 -.0337717
orden_n		.2290269	.0618843	3.70	0.000	.1077359 .3503178
ocupado_jefe		.2053767	.0522936	3.93	0.000	.102883 .3078703
educa_jefe		-.0151349	.00544	-2.78	0.005	-.0257972 -.0044727
ingresos_h~e		.0007741	.0002392	3.24	0.001	.0003054 .0012429
_cons		-.1307518	.104657	-1.25	0.212	-.3358758 .0743721
-----+-----						

There are observations with identical propensity score values.
The sort order of the data could affect your results.
Make sure that the sort order is random before calling `psmatch2`.

Variable	Sample	Treated	Controls	Difference	S.E.	T-stat
-----+-----						
ha_nchs2	Unmatched	- .643956819	-.976453847	.332497028	.03380015	9.84
	ATT	- .643655499	-.993700068	.350044569	.047347223	7.39
-----+-----						

Note: S.E. for ATT does not take into account that the propensity score is estimated.

psmatch2:	psmatch2: Common		
Treatment	support		
assignment	Off suppo	On suppor	Total
-----+-----			
Untreated	0	2,048	2,048
Treated	2	1,950	1,952
-----+-----			
Total	2	3,998	4,000

ha_nchs2 = puntaje Z de estatura según la edad

D = indicador de participación en el programa

pscore = probabilidad de participación en el programa

personas = tamaño del hogar

orden_n = orden de nacimiento del niño

ocupado_jefe = indicador igual a 1 si el jefe de hogar trabaja

educa_jefe = años de escolaridad del jefe de hogar

ingresos_hogar_jefe = ingresos del jefe del hogar en decenas de miles de pesos colombianos

Resultado 6.6:

```
. psmatch2 D $X, outcome(ha_nchs2) com kernel
```

Probit regression	Number of obs = 4000
	LR chi2(5) = 63.52
	Prob > chi2 = 0.0000
Log likelihood = -2739.6749	Pseudo R2 = 0.0115

	D	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
-----+-----							
personas		-.0547807	.0107191	-5.11	0.000	-.0757897	-.0337717
orden_n		.2290269	.0618843	3.70	0.000	.1077359	.3503178
ocupado_jefe		.2053767	.0522936	3.93	0.000	.102883	.3078703
educa_jefe		-.0151349	.00544	-2.78	0.005	-.0257972	-.0044727
ingresos_h~e		.0007741	.0002392	3.24	0.001	.0003054	.0012429
_cons		-.1307518	.104657	-1.25	0.212	-.3358758	.0743721
-----+-----							

Variable	Sample	Treated	Controls	Difference	S.E.	T-stat
-----+-----						
ha_nchs2 Unmatched		-.643956819	-.976453847	.332497028	.03380015	9.84
ATT		-.643655499	-.966638592	.322983092	.034286897	9.42
-----+-----						

Note: S.E. for ATT does not take into account that the propensity score is estimated.

psmatch2:	psmatch2: Common		
Treatment	support		
assignment	Off suppo	On suppor	Total
-----+-----+-----			
Untreated	0	2,048	2,048
Treated	2	1,950	1,952
-----+-----+-----			
Total	2	3,998	4,000

bootstrap r(att) : psmatch2 D \$X, out(ha_nchs2) com kernel

(running psmatch2 on estimation sample)

Note: S.E. for ATT does not take into account that the propensity score is estimated.

Bootstrap replications (50)

-----+--- 1 ---+--- 2 ---+--- 3 ---+--- 4 ---+--- 5
 50

Bootstrap results

Number of obs = 4000

Replications = 50

command: psmatch2 D personas orden_n ocupado_jefe educa_jefe ingresos_
 hogar_jefe, out(ha_nchs)
 com kernel
 _bs_1: r(att)

	Observed	Bootstrap			Normal-based	
	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
-----+-----+-----						
_bs_1	.3229831	.0430993	7.49	0.000	.23851	.4074561
-----+-----+-----						

ha_nchs2 = puntaje Z de estatura según la edad

D = indicador de participación en el programa

pscore = probabilidad de participación en el programa

personas = tamaño del hogar

orden_n = orden de nacimiento del niño

ocupado_jefe = indicador igual a 1 si el jefe de hogar trabaja

educa_jefe = años de escolaridad del jefe de hogar

ingresos_hogar_jefe = ingresos del jefe del hogar en decenas de miles de pesos

_bs_1 indica que el coeficiente fue estimado mediante bootstrap

La tabla 6.1 muestra que, para el caso de Canasta, dados los datos existentes, el impacto estimado del programa no varía mucho ni dependiendo del método de estimación ni del soporte común elegidos.

TABLA 6.1. Impacto estimado del programa

Método de emparejamiento	Soporte común	
	Mínimo-máximo (preestablecido)	Recorte (<i>trimming</i>)
Vecinos más cercanos		
1	0.350	0.340
5	0.323	0.325
10	0.322	0.317
Distancia máxima		
0.001	0.333	0.326
0.005	0.326	0.322
Local lineal	0.319	0.319
<i>Kernel</i>	0.322	0.330

Dobles diferencias emparejadas

Supongamos que tenemos a disposición observaciones del mismo individuo durante dos períodos: una antes y otra después de la intervención. Se pueden combinar los métodos de emparejamiento y el de dobles diferencias para calcular el impacto del programa. Como el método de emparejamiento asume que la selección en el programa se basa única y exclusivamente en características observables de los individuos, podemos usar la información longitudinal para eliminar el efecto de la selección en el programa que depende de variables no observables o no disponibles en la base de datos, siempre y cuando éstas permanezcan constantes en el tiempo.

En este capítulo utilizaremos la metodología de dobles diferencias emparejadas, para evaluar la evolución de la variable “estatura según la edad” de los individuos en dos períodos. Lo primero que debemos hacer es generar la variable de diferencia entre las dos observaciones ΔY :

$$\Delta Y = Y_{2i} - Y_{1i}$$

donde Y_{2i} es la estatura según la edad del individuo i en el período dos (después de la intervención) y Y_{1i} es la estatura según la edad del mismo individuo i en el período uno (antes de la intervención).

Ahora la variable dependiente es la *diferencia* en la estatura según la edad, antes y después del programa. Ésta es la variable de interés o variable de resultado en este caso, en vez del simple puntaje Z utilizado en

los ejercicios anteriores (resultados 6.5 y 6.6). Así, cada diferencia en el puntaje Z en el grupo de tratamiento se emparejará con un conjunto de controles, según el algoritmo de emparejamiento elegido. El método de dobles diferencias emparejadas evalúa la diferencia en la *evolución* de la estatura según la edad entre individuos tratados y no tratados.

En el resultado 6.7 se muestra el impacto del programa con dobles diferencias emparejadas, usando el emparejamiento por vecino más cercano. En este caso, el impacto estimado del programa en el soporte común es de 0.23 desviaciones estándar. Este resultado es alrededor de dos terceras partes del estimado usando simplemente los métodos de emparejamiento descritos en la sección anterior. Lo que esto sugiere es que, para este caso, la selección en el programa depende de variables tanto observables como no observables o no disponibles en la base de datos. Si sólo contamos con una observación en el tiempo, y estimamos el impacto del programa usando PSM, estaremos sobrestimando efectos. Al contar con información longitudinal de los mismos individuos, podemos controlar también por el sesgo de selección en variables no observables, siempre y cuando éstas no varíen en el tiempo. Este resultado enfatiza que el supuesto de PSM, de que la selección en el programa depende únicamente de variables observables, es bastante fuerte.

Resultado 6.7:

<pre>. psmatch2 D \$X, outcome(delta_ha) n(1) com</pre>						
Probit regression				Number of obs = 4000		
				LR chi2(5) = 63.52		
				Prob > chi2 = 0.0000		
Log likelihood = -2739.6749				Pseudo R2 = 0.0115		
	D	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]
	personas	-.0547807	.0107191	-5.11	0.000	-.0757897 -.0337717
	orden_n	.2290269	.0618843	3.70	0.000	.1077359 .3503178
	ocupado_jefe	.2053767	.0522936	3.93	0.000	.102883 .3078703
	educa_jefe	-.0151349	.00544	-2.78	0.005	-.0257972 -.0044727
	ingresos_h~e	.0007741	.0002392	3.24	0.001	.0003054 .0012429
	_cons	-.1307518	.104657	-1.25	0.212	-.3358758 .0743721

There are observations with identical propensity score values.
The sort order of the data could affect your results.
Make sure that the sort order is random before calling psmatch2.

Variable	Sample	Treated	Controls	Difference	S.E.	T-stat
delta_haUnmatched		.073536416	-.164157115	.237693531	.003124728	76.07
ATT		.072849661	-.162843999	.23569366	.005394563	43.69

Note: S.E. for ATT does not take into account that the propensity score is estimated.

psmatch2:	psmatch2: Common			
Treatment	support			
assignment	Off suppo	On suppor		Total
Untreated	0	2,048		2,048
Treated	390	1,562		1,952
Total	390	3,610		4,000

delta_ha = cambio en el puntaje Z de estatura según la edad entre el período 1 y el 2

D = indicador de participación en el programa

pscore = probabilidad de participación en el programa

personas = tamaño del hogar

orden_n = orden de nacimiento del niño

ocupado_jefe = indicador igual a 1 si el jefe de hogar trabaja

educa_jefe = años de escolaridad del jefe de hogar

ingresos_hogar_jefe = ingresos del jefe del hogar en decenas de miles de pesos

6.8. Conclusiones y ejemplos

El método de PSM es flexible y tiene requerimientos de datos mucho menos exigentes que los demás métodos reseñados en este libro. Se puede aplicar a un único levantamiento de información, siempre y cuando exista información para los grupos de tratamiento y control. Por tanto, se usa con mucha frecuencia. Sin embargo, la confiabilidad de sus resultados depende de manera crucial de qué tan factible es que se cumplan los supuestos para el caso de estudio. En particular, los resultados son confiables siempre y cuando existan razones para pensar que las variables no observables o no disponibles en la base de datos, que determinan la variable resultado, no son un determinante de la participación en el programa. Este supuesto se viola con frecuencia. Este método es preferible al simple modelo de diferencias con regresores adicionales cuando los grupos de tratamiento y control son disímiles, ya que al reducir la comparación a la región de soporte común se disminuye la posibilidad de obtener estimaciones basadas en extrapolaciones que son difíciles de fundamentar. Si bien dista mucho de ser un método ideal, con buenos datos y decisiones acertadas por parte del investigador, PSM puede ser un método poderoso.

Para ejemplificar el uso de PSM se presentan dos ejemplos. Por un lado, una evaluación del programa *Job Training Partnership Act* (JTPA), que es uno de los artículos pioneros en la técnica. Por el otro, el informe de línea de base de la evaluación de Familias en Acción, un programa de transferencias condicionadas que se implementó en Colombia.

Ejemplo 1: Heckman, Ichimura y Todd (1997)

El artículo presenta los resultados del experimento JTPA (*Job Training Partnership Act*), que estaba orientado a evaluar el programa de entrenamiento laboral más importante de Estados Unidos. El programa JTPA provee entrenamiento directo y en el trabajo, así como asistencia en la búsqueda de empleo a personas en condiciones de pobreza durante los seis meses anteriores. Aleatoriamente se asignó a dos tercios de los solicitantes al tratamiento y a un tercio al grupo de control. Los autores tienen un experimento social al tener asignación aleatoria de cupos. Los solicitantes asignados aleatoriamente al grupo de control serán denominados controles, mientras que llamaremos grupo de comparación a los elegibles que decidieron no participar. Se recolectó información longitudinal de tratados, controles y un grupo de comparación de elegibles que decidieron no participar. Por tanto, los autores pueden comparar los resultados generados por diferentes procedimientos de emparejamiento y determinar qué tan cercanos son con respecto a los de un experimento social. La participación en el programa, calculada usando un modelo logit, depende de factores tales como características de la persona (educación, edad, sexo, entre otras), historia de desempleo reciente, el comportamiento de los ingresos laborales durante los últimos seis meses, así como los períodos recientes de desempleo sufridos por la persona. Para las mujeres adultas, la historia marital es también determinante en la participación, pues es más probable que participen mujeres que se han separado o divorciado recientemente y que, por tanto, están enfrentando transiciones en el ciclo de vida. Se presenta a continuación el impacto del programa por grupos demográficos, comparando los ingresos del grupo de tratamiento con los controles y con el grupo de comparación 18 meses después de la asignación aleatoria.

La primera columna presenta el impacto del programa usando los datos experimentales (tratamiento *vs.* controles) para toda la muestra. El impacto experimental es el impacto mensual promedio en los ingresos de los trabajadores, medido en dólares, durante un período de 18 meses después de la intervención aleatoria. Los hombres adultos que se beneficiaron del programa ganan en promedio US\$ 44 más por mes que los no beneficiarios. La segunda repite el cálculo sólo para las observaciones en

el soporte común: el impacto ajustado. En el soporte común, los hombres adultos tratados ganan US\$ 61 más al mes que los controles. En la tercera se presenta el sesgo generado por no restringir al soporte común, como porcentaje del impacto experimental. Así, la diferencia sobre los hombres adultos entre el impacto experimental y el impacto experimental restringido al soporte común representa 39% del impacto experimental.⁴⁹ Es decir, al no restringir al soporte común y, por tanto, comparar observaciones que no son necesariamente comparables, se incurre en un sesgo del impacto del programa de 39% para los hombres adultos. Note que en general el sesgo no es muy grande, excepto para las mujeres jóvenes (2500%).

Las últimas cuatro columnas presentan el sesgo generado por los resultados del impacto, según diferentes métodos de pareo, como porcentaje del impacto experimental.⁵⁰ Los métodos comparados son la simple diferencia de medias entre el grupo de control (experimental) y el grupo de comparación (columna 4), el método de N-vecino cercano sin restringir a soporte común (columna 5), el mismo método pero restringiendo la muestra al soporte común (columna 6), y el estimador local lineal (columna 7).

Los resultados sugieren que en muestras pequeñas hay mucha heterogeneidad en el impacto para los diferentes grupos demográficos. A veces la simple comparación de medias genera resultados más cercanos a los experimentales que los métodos de emparejamiento, pero a veces se mejora la estimación usando PSM. En general, el sesgo se reduce cuando el estimador de emparejamiento se restringe al soporte común.

Aunque no es posible generalizar los resultados presentados más allá del caso en cuestión, el artículo provee mensajes importantes. Los métodos de emparejamiento generan un sesgo considerable con respecto a los estudios experimentales y, por tanto, no son la solución de todos los problemas evaluativos. La efectividad de cada método de pareo está limitada por la calidad de los datos disponibles, y ningún método de pareo “funciona” en todas las circunstancias. En general, el pareo dentro del soporte común genera menos sesgo que si no se impone esta condición. Por tanto, comparar lo no comparable, es decir, violar el supuesto de soporte común, genera un sesgo importante en los resultados.

49 Para los hombres adultos, la diferencia entre el impacto experimental para toda la muestra y el impacto sobre el soporte común es $61 - 44 = 17$. Si se divide entre el impacto experimental, $17 / 44$, el sesgo es 39%.

50 El artículo compara otros métodos de emparejamiento que tienen mejores resultados que los que se presentan aquí, particularmente el método de dobles diferencias emparejadas (*matched double-differences*). Sin embargo, por el nivel de complejidad, no se incluyen en el presente texto. Se remite al lector interesado a leer el artículo original.

TABLA 6.2. Diferencias promedio en los ingresos después del programa

	Impacto experim. (impacto mensual promedio en dólares)	Impacto experim. ajustado (para las personas en el soporte común)	Sesgo (como % del impacto)	Diferencia de medias entre controles y no participantes (sesgo como % del impacto)	Vecino más cercano sin soporte común (sesgo como % del impacto)	Vecino más cercano en soporte común (sesgo como % del impacto)	Emparejamiento local lineal en la prob. de participación (sesgo como % del impacto)
Hombres adultos	44 (17)	61 (17)	39%	775%	142%	177%	108%
Mujeres adultas	29 (9)	35 (12)	21%	113%	358%	157%	130%
Hombres jóvenes	-58 (14)	-36 (18)	38%	34%	382%	170%	67%
Mujeres jóvenes	-1 (11)	25 (18)	2500%	7059%	15000%	5441%	8971%

Nota: Los errores estándar (en paréntesis) fueron calculados usando *bootstrap*. Extractos de las tablas 4, 5a y 5b de Heckman, Ichimura y Todd (1997).

Ejemplo 2: Attanasio y Gómez (2004)

Familias en Acción es un programa de transferencias condicionadas que originalmente fue implementado por el Gobierno colombiano para mejorar la acumulación de capital humano de la población vulnerable en las zonas rurales. Tiene tres componentes principales: nutrición (transferencia monetaria a la madre para mejorar la nutrición de los niños entre 0 y 5 años), salud (vacunas y controles de crecimiento y desarrollo) y educación (transferencia condicionada a asistencia escolar).

En el inicio del programa participaron 622 municipios de 26 departamentos del país, que contaban con los siguientes recursos: infraestructura de educación básica y salud, al menos un banco, menos de 100,000 habitantes, que el alcalde registrara el municipio y entregara la base de datos del nivel 1 del Sisbén. Dentro de cada municipio elegible, todas las familias Sisbén 1 con niños entre 0 y 17 años eran beneficiarios potenciales.

Para evaluar el programa se siguió una metodología cuasi experimental. Se escogió una muestra estratificada de 50 municipios participantes en el programa como grupo de tratamiento. El grupo de control estaba conformado por 50 municipios parecidos a los anteriores, en cuanto a localización geográfica y oferta de servicios de educación y salud, pero que no formaban parte del programa por no tener banco o por tener un poco más de 100,000 habitantes.

Cuando empezó la evaluación el programa ya había iniciado operaciones en unos municipios, seleccionados de manera no aleatoria, y algunos beneficiarios ya habían recibido el primer pago en el momento del levantamiento de la línea de base. Por tanto, el grupo de tratamiento se divide en dos: “tratamiento con pago” (TCP) y “tratamiento sin pago” (TSP). Así, los grupos de control correspondientes se llaman “control con pago” (CCP) y “control sin pago” (CSP). Dentro de los municipios de la muestra se escogió una muestra de hogares elegibles. Entonces, el impacto del programa se medirá como la diferencia en las variables de interés entre los individuos de los grupos de tratamiento y control.

Usando la información de línea de base levantada en 2002, el artículo presenta una evaluación de impacto preliminar comparando los municipios TCP y TSP. Como la asignación de municipios a los grupos de tratamiento y control no fue completamente aleatoria, las muestras pueden diferir en algunas dimensiones. Los autores usan PSM en la comparación de los hogares de tratamiento y control para controlar por estas diferencias. La probabilidad de participación en el programa se estima usando

un probit. En esta estimación, además de los controles individuales, familiares y de la comunidad, se incluyen variables adicionales para predecir el impacto sobre escolaridad (si el niño asistía al colegio en el año anterior al inicio del programa) y el impacto nutricional (estatura de la madre).

Dado que uno de los aspectos centrales del programa es promover la educación, los efectos preliminares sobre la probabilidad de estar matriculado se reportan en la tabla 6.3. La primera columna muestra el impacto del programa y su error estándar, mientras que la segunda presenta el porcentaje de hogares TCP emparejados, que es un indicador de la calidad del emparejamiento. El programa no tiene efectos significativos en la probabilidad de estar matriculado, para los niños entre 7 y 13 años, lo cual no es sorprendente, pues los niveles de matrícula en estos niveles son relativamente altos de por sí. En cambio, en las zonas urbanas de los municipios el programa aumenta considerablemente la probabilidad de estar matriculado para los jóvenes entre 14 y 17 años. Además, como un alto porcentaje de las observaciones están emparejadas, las dos muestras son bastante comparables.

TABLA 6.3. Impacto sobre la probabilidad de estar matriculado para los niños entre 7 y 17 años

	Variable	Impacto del programa (PSM)	Porcentaje de la muestra TCP emparejada
Urbano	Probabilidad de estar matriculado, 7-13 años	0.003 (0.022)	88.9
	Probabilidad de estar matriculado, 14-17 años	0.138* (0.066)	87.5
Rural	Probabilidad de estar matriculado, 7-13 años	0.012 (0.028)	92.1
	Probabilidad de estar matriculado, 14-17 años	0.055 (0.053)	86.6

Errores estándar en paréntesis. * Significativo al 10%.

Nota: Extracto de la tabla 4.3.1 de Attanasio y Gómez (2004).

Otro aspecto de interés es el efecto del programa sobre los indicadores de nutrición de los niños entre 0 y 6 años de edad, ya que es uno de los factores determinantes para la acumulación de capital humano. Los resultados preliminares del programa sobre el estado nutricional de los niños, medidos como peso por edad y peso por estatura, se presentan en la tabla 6.4. De nuevo, la primera columna presenta los resultados de emparejamiento y la segunda el porcentaje de la muestra emparejada.

El programa tuvo un efecto significativo sobre el peso de los niños que viven en las zonas rurales de los municipios bajo ambas medidas.

TABLA 6.4. Impacto sobre el estado nutricional de los niños entre 0 y 6 años

	Variable	Impacto del programa (PSM)	Porcentaje de la muestra TCP emparejada
Urbano	Peso según la estatura	1.867 (1.428)	71.1
	Peso según la edad	2.911 (2.512)	71.1
Rural	Peso según la estatura	2.318** (1.337)	67.5
	Peso según la edad	2.449* (1.540)	67.5

Errores estándar en paréntesis. **Significativo al 5%. *Significativo al 10%.

Nota: Extracto de la tabla 4.5.2 de Attanasio y Gómez (2004).

Bibliografía

- Abadie, A. y G. Imbens, 2008, "On the Failure of the Bootstrap for Matching Estimators" *Econometrica*, vol. 76(6), 1537-1557.
- Attanasio, O. y L. Gómez, 2004, "Informe de Línea de Base de la Evaluación de Familias en Acción". Directores: Orazio Attanasio y Luis Carlos Gómez (http://www.ifs.org.uk/e depo/publications.php?publication_id=4348).
- Blundell, R. y M. Costa Dias, 2009, "Alternative Approaches to Evaluation in Empirical Microeconomics," *Journal of Human Resources*, vol. 44(3), 565-640.
- Bryson, A., R. Dorsett, y S. Purdon, 2002, "The Use of Propensity Score Matching in the Evaluation of Labour Market Policies" Working Paper No. 4, Department for Work and Pensions, UK.
- Caliendo, M. y S. Kopeinig, 2005, "Some Practical Guidance for Implementation of Propensity Score Matching", IZA Discussion Paper Series No. 1588.
- Cochran, W., 1968, "The Effectiveness of Adjustment by Subclassification in Removing Bias in Observational Studies", *Biometrics*, 24, 295-314.
- Dehejia, R., 2005, "Practical Propensity Score Matching: A Reply to Smith and Todd", *Journal of Econometrics*, 125, 355-364.
- Frölich, M., 2004, "Finite-Sample Properties of Propensity-Score Matching and Weighting Estimators," *The Review of Economics and Statistics*, MIT Press, vol. 86(1), 77-90.
- Heckman, J., H. Ichimura y P. Todd, 1997, "Matching As an Econometric Evaluation Estimator: Evidence from Evaluating a Job Training Programme", *Review of Economic Studies*, 64, 605-654.
- Heckman, J., H. Ichimura y P. Todd, 1998, "Matching As an Econometric Evaluation Estimator", *Review of Economic Studies*, 65 (2), 261-294.
- Heckman, J., H. Ichimura, J. Smith y P. Todd, 1998, "Characterizing Selection Bias Using Experimental Data", *Econometrica*, 66, 1017-1098.

Imbens, G. y D. Rubin, 2010, *Causal Inference in Statistics and Social Sciences*, manuscrito, Harvard University.

Rosenbaum, P. y D. Rubin, 1983, "The Central Role of the Propensity Score in Observational Studies for Causal Effects", *Biometrika*, 70, 41-50.

Smith, J., 2000, "A Critical Survey of Empirical Methods for Evaluating Active Labor Market Policies", *Schweizerische Zeitschrift fr Volkswirtschaft und Statistik*, 136 (3), 1-22.

Smith, J. y P. Todd, 2005, "Does Matching Overcome LaLonde's Critique of Non-Experimental Estimators?", *Journal of Econometrics*, 125 (1-2), 305-353.

