

Malos controles en econometría causal

Tres casos clásicos con DAGs y ejemplos

Controlar más no siempre mejora la identificación.




- ① **Buen control**: controlar por una **causa común** de tratamiento y resultado.
- ② **Mal control** caso 1: **post-tratamiento / mediador**.
- ③ **Mal control** caso 2: **colisionador / selección endógena**.
- ④ **Mal control** caso 3: **proxy contaminado**: parece proxy del confounder, pero ya incorpora efecto del tratamiento.

Regla central

Controlar variables **pretratamiento** que cierran **back-door paths**. Evitar variables que son **resultado del tratamiento** o **efectos comunes**.


Punto de partida: buen control vs. mal control

Buen control (confounder)



Si X causa tanto D como Y , condicionar en X ayuda a identificar el efecto de D sobre Y .


Mal control



Si Z es consecuencia de D o un efecto común, condicionar en Z cambia el parámetro estimado o introduce sesgo.

Los tres malos controles en una sola lámina


1. Mediador



$$D \rightarrow M \rightarrow Y$$

Controlar M bloquea parte del efecto total.


2. Colisionador



$$D \rightarrow C \leftarrow U \rightarrow Y$$

Controlar C abre un camino espurio.


3. Proxy contaminado



$$D \rightarrow L \leftarrow U \rightarrow Y$$

L mezcla tratamiento y no observables.

Caso 1: post-tratamiento / mediador



$$D \rightarrow M \rightarrow Y$$


Idea: Si controlas por M , bloqueas parte del efecto causal de D sobre Y .

- ▶ Si el objetivo es el **efecto total**, M es un **Mal control**.
- ▶ El coeficiente de D pasa a reflejar algo más cercano a un **efecto directo**.
- ▶ El resultado puede subestimar fuertemente el impacto total.


Ejemplos: post-tratamiento / mediador

Tratamiento D	Mal control M	Resultado Y
Educación universitaria	Ocupación / tipo de empleo	Salario
Capacitación laboral	Puntaje del examen final	Ingreso o productividad
Tamaño de clase	Tiempo de atención individual	Aprendizaje
Microcrédito	Inversión del negocio	Ganancias
Seguro de salud	Uso de servicios médicos	Gasto catastrófico o salud
Transferencia monetaria	Consumo del hogar	Nutrición o escolaridad
Beca universitaria	Horas de estudio actuales	Rendimiento / graduación
Campaña de vacunación	Anticuerpos posteriores	Hospitalización

DAG de referencia



Caso 2: colisionador / selección endógena



$$D \rightarrow C \leftarrow U \rightarrow Y$$

Idea: Sin condicionar en C , ese camino está cerrado. Si controlas por C , lo abres.


- ▶ El sesgo aparece **por controlar**.
- ▶ Es frecuente al restringir la muestra: solo empleados, solo admitidos, solo sobrevivientes, solo prestatarios.
- ▶ También surge al incluir una variable de **selección** en la regresión.

Ejemplos: colisionadores con U no observado


D observado	Colisionador C	U no observado	Y
Conexiones	Contratación	Habilidad	Productividad
Red académica	Publicación	Calidad del paper	Citaciones
Application effort	Scholarship	Academic talent	Academic outcomes
Investor network	VC funding	Project quality	Firm performance
Exercise	Hospitalization	Health shock	Health
Family wealth	College admission	Academic preparation	GPA
Lobbying access	Contract award	Project suitability	Project success
Insurance coverage	Specialist visit	Illness severity	Health spending

DAGs de colisionadores: ejemplos


Mercado laboral




Publicación académica



Startup financing




Hospitalization




Selección muestral como colisionador

1. Solo empleados




Restringir la muestra a ocupados puede inducir sesgo al estudiar el efecto de la educación sobre salario.

2. Solo sobrevivientes



Analizar solo firmas sobrevivientes abre selección endógena al comparar desempeño posterior.

Caso 3: proxy contaminado



$$D \rightarrow L \leftarrow U \rightarrow Y$$


Idea: L parece un proxy útil de U , pero como también es afectado por D , se vuelve un mal control.

- ▶ Es frecuente cuando no se observa la verdadera fuente de heterogeneidad.
- ▶ El control luce razonable porque contiene información sobre U .
- ▶ El problema es que también contiene efecto del tratamiento.

Ejemplos: proxies contaminados

Tratamiento D	Proxy contaminado L	U no observado	Y
Educación	Test de habilidad tomado después de estudiar	Habilidad innata	Salario
Capacitación	Evaluación de desempeño posterior	Motivación / habilidad	Ingreso
Programa nutricional	Biomarcador posterior	Salud de base	Crecimiento
Terapia médica	Adherencia observada tras iniciar tratamiento	Severidad latente	Salud
Subsidio escolar	Asistencia actual	Motivación familiar	Rendimiento
Crédito empresarial	Formalización posterior	Capacidad gerencial	Ganancias
Información financiera	Score crediticio posterior	Disciplina financiera	Acceso a crédito

DAG de referencia



Comparación rápida de los tres casos

Caso	DAG	Qué pasa si controlas	Ejemplo corto
Post-tratamiento / mediador	$D \rightarrow M \rightarrow Y$	Bloqueas parte del efecto total	Educación $\rightarrow$ ocupación $\rightarrow$ salario
Colisionador	$D \rightarrow C \leftarrow U \rightarrow Y$	Abres un camino espurio	Conexiones $\rightarrow$ contratación $\leftarrow$ habilidad
Proxy contaminado	$D \rightarrow L \leftarrow U \rightarrow Y$	Mezclas tratamiento y no observables	Educación $\rightarrow$ test tardío $\leftarrow$ habilidad

Qué sí controlar

Variables **pretratamiento** que sean causas de D y de Y , o que ayuden a bloquear back-door paths sin ser descendientes de D ni colisionadores.

Checklist

- ① **Timing:** ¿la variable está determinada antes del tratamiento?
- ② **Dirección causal:** ¿puede el tratamiento afectar esa variable?
- ③ **Estructura DAG:** ¿la variable recibe dos flechas?
- ④ **Estimando:** ¿se busca efecto total o efecto directo?
- ⑤ **Selección muestral:** ¿la muestra está condicionada por empleo, supervivencia, admisión, acceso o permanencia?
- ⑥ **Proxy tentador:** ¿el supuesto proxy fue medido después del tratamiento?

Referencias sugeridas

- ▶ Angrist, J. D., & Pischke, J.-S. *Mostly Harmless Econometrics*. Princeton University Press.
- ▶ Angrist, J. D., & Pischke, J.-S. *Mastering 'Metrics*. Princeton University Press.
- ▶ Cinelli, C., Forney, A., & Pearl, J. (2022/2024). *A Crash Course in Good and Bad Controls*.
- ▶ Elwert, F., & Winship, C. (2014). Endogenous selection bias.
- ▶ Pearl, J. *Causality*. Cambridge University Press.