

$$y_i = \alpha + \tau D_i + \chi \beta + w \delta + \epsilon$$

Donde $\epsilon \sim \text{iid}(0, \sigma_\epsilon^2)$

$$D_i = \begin{cases} 0 & \text{Si } i \text{ No participa} \\ 1 & \text{Si } i \text{ Participa} \end{cases}$$

χ = Características pre-determinadas y que NO son influenciadas por D

w = Características NO observadas (Potencialmente correlacionadas con D y y)

Para facilitar notación voy a excluir del análisis las variables χ pero rewerde que siempre debe controlar por ellas



Andrew Goodman-Bacon @agoodmanbacon · 5h

"To identify the causal effect of masks we circle parts of a graph"


$$y = \alpha + \tau D + w \delta + \epsilon =$$



Dr. Angela Rasmussen @angie_rasmussen · Mar 28

This graph has been making the rounds today on the effect of masks at reducing #SARSCoV2 #HCoV19 #COVID19 #coronavirus transmission. There's a lot more going on here than mask/no mask

[Show this thread](#)



$$\frac{\Delta y}{\Delta D} = \tau + \underbrace{\frac{\Delta w}{\Delta D}}$$


Sesgo de Selección

EJEMPLO



Solución:

Variables Instrumentales.



Condiciones de la variable instrumental

- 1 Relevancia $\text{Cov}(D, Z) \neq 0$ (Español: Z está altamente relacionado X)
- 2 Validez: $\text{Cov}(Z, \mu) = 0$ (Español: Z es tan buena como si fuera asignada de manera aleatoria // La única relación entre Z y Y es a través de (Luego de controlar por cualquier control X))

Intuición.

$$\hat{T}_{IV} = \frac{\text{Cov}(Y, Z)}{\text{Cov}(D, Z)} \rightarrow \text{De hecho se necesita que } \text{Cov}(Y, Z) \neq 0$$

$$\text{Cov}(D, Z) \rightarrow \text{Se necesita por definición que } \text{Cov}(D, Z) \neq 0$$

En qué casos NO se cumple la condición de Validez (Exogeneidad)

- 1 $Z_i \leftrightarrow Y_i$
- 2 $Z_i \leftrightarrow \mu_i(w_i)$
- 3 $Z_i \leftrightarrow X_i$ (se puede controlar por estas características)

Traducción: Si Z está correlacionada con Y (de manera causal o NO) a través de cualquier relación que no sea por D .

EJEMPLOS

$$\text{Saber}_i = \alpha + \tau \text{Privado}_i + u_i$$

$Z \Rightarrow$ Lotería de Paces


$$Z_i = \begin{cases} 0 & \text{Si perdió la lotería} \\ 1 & \text{Si ganó la lotería} \end{cases}$$

$\text{Cor}(\text{Privado}, u_i) \neq 0$ por sesgo de selección:

- * pre-saber
- * motivación
- * capital cultural
- * calidad en aspiraciones

! Relevante ?

Δ Valido ?



Otros Ejemplos

Experimentos naturales y cuasi experimentales

- Angrist et Evans (1998), "Children and Their Parents Labor Supply: Evidence from Exogenous Variation in Family Size"
 - Tener hijos afecta la carrera profesional de las mujeres?
 - Hecho estilizado: madres trabajan menos y tienen salarios menores
 - Endogeneidad: esta correlación negativa implica que es difícil trabajar con hijos o que las mujeres poco comprometidas con el mercado laboral tienen más hijos?

Sex of first two children in families with two or more children	All women			
	1980 PUMS (394,835 observations)		1990 PUMS (380,007 observations)	
	Fraction of sample	Fraction that had another child	Fraction of sample	Fraction that had another child
one boy, one girl	0.494	0.372 (0.001)	0.495	0.344 (0.001)
two girls	0.242	0.441 (0.002)	0.241	0.412 (0.002)
two boys	0.264	0.423 (0.002)	0.264	0.401 (0.002)

! Relevante ?

Δ Valido ?

Evans and Lien (2005), "The benefits of prenatal care: evidence from a PAT bus strike", Journal of Econometrics

- ¿La visitas prenatales tienen un impacto en la salud de los niños?
- Endogeneidad: embarazos de alto riesgo pueden requerir más cuidado prenatal
- Instrumento: utilizar una importante huelga en el transporte público que se produjo en una ciudad de los EE.UU.
- Intuición: algunas mujeres que estaban embarazadas durante la huelga de autobuses pierden la visita prenatal.

! Relevante ?

Δ Valido ?

Angrist Kruger (1992) Estimating the Payoff to Schooling Using the Vietnam-Era Draft Lottery

- ① El instrumento los años de educación con la lotería de Vietnam Draft

Daron Acemoglu, Camilo García-Jimeno, and James A. Robinson (2015) State Capacity and Economic Development: A Network Approach

- ① Instrumentan la capacidad estatal usando las carreteras de la colonia.

⚠ Relevante ?

⚠ Valido ?

Fuentes de Variables Instrumentales

- ① Teoría combinada con una recopilación de datos inteligente (Ejemplo: la distancia desde el centro de capacitación laboral varía el costo de la participación en la capacitación, y nos interesa el efecto de la capacitación en los salarios)
- ② Variación exógena en las políticas o la implementación de programas, a lo largo del tiempo o en el espacio (Ejemplo: lotería de Vietnam, interesada en el efecto del servicio militar en los salarios)
- ③ Naturaleza (el clima tormentoso varía la oferta de peces, lo que nos permite saber cómo es realmente la demanda de palitos de pescado en función de los precios)
- ④ Roll Your Own (Ejemplo: un experimento , o estímulo aleatorio para iniciar el tratamiento si el experimento es inviable / no ético)

$r \rightarrow$ # de variable endógenas

$D_1, D_2, D_3, \dots$ D

X_s var de control exógenas

$p \rightarrow$ # de variables instrumentales

$$r = p$$

Perfectamente identificado

$\hat{T}_{VI} \rightarrow$ Variables Instrumentales

$$r < p$$

Sobre-identificado

$\uparrow$
 $H_0: \alpha = 0$

$$r > p$$

Sub-identificado

Parla //

$$y = D\tau + \varepsilon \longrightarrow$$

$\hookrightarrow \text{Cov}(\varepsilon, D) \neq 0$ sesgo de selección

$$\text{Cov}(Z, D) \neq 0$$

Probar $\checkmark$

$$\text{Cov}(Z, \varepsilon) = 0$$

No hay forma de probarlo

$$E[Z'\varepsilon | X] = 0$$

$$Z'\varepsilon = 0$$

$$\varepsilon = y - D\tau$$

$$Z'[y - D\tau] = 0$$

$$Z'y - Z'D\tau = 0$$

$$\underbrace{(Z'D)^{-1}}_{\tau} Z'D\tau = (Z'D)^{-1} Z'y$$

$$\hat{\tau}_{\text{IV}} = (Z'D)^{-1} Z'y$$

$$\cong \frac{\text{Cov}(Z, y)}{\text{Cov}(Z, D)}$$


$$E[\hat{\tau}_{\text{IV}}] \neq \tau \quad \text{Sesgado}$$

$$\text{plim}[\hat{\tau}_{\text{IV}}] = \tau \quad \text{Consistente.}$$

$$\text{Var}[\hat{\tau}_{\text{IV}}] = \text{Var}[(Z'D)^{-1} Z'y]$$

)

$$T_{\text{WALD}} = \frac{E[Y|D=1] - E[Y|D=0]}{E[D|Z=1] - E[D|Z=0]}$$



$$\begin{aligned}
\text{Var}[\hat{\tau}_{\text{IV}}] &= \text{Var}[(Z'D)^{-1}Z'[D\tau + \epsilon]] \\
&= \text{Var}[(Z'D)^{-1}Z'D\tau + (Z'D)^{-1}Z'\epsilon] \\
&= \text{Var}[\tau + (Z'D)^{-1}Z'\epsilon] \\
&= \text{Var}[\underbrace{(Z'D)^{-1}Z'}_{A}\epsilon] \quad \text{Var}(A\epsilon) = A\text{Var}(\epsilon)A'
\end{aligned}$$

$$\epsilon \sim \text{iid}(0, \sigma_\epsilon^2 \mathbb{I}_n)$$

$$\begin{aligned}
&= (Z'D)^{-1}Z' \sigma_\epsilon^2 \mathbb{I}_n Z (Z'D)^{-1'} \\
&= \sigma_\epsilon^2 (Z'D)^{-1}Z'Z (Z'D)^{-1'}
\end{aligned}$$

$$\epsilon \sim d(0, \sigma_\epsilon^2 \Psi)$$

$$\begin{aligned}
&= (Z'D)^{-1}Z' \sigma_\epsilon^2 \Psi Z (Z'D)^{-1'} \\
&= \sigma_\epsilon^2 (Z'D)^{-1}Z'\Psi Z (Z'D)^{-1'}
\end{aligned}$$

$$\text{Var}(\hat{\tau}_{\text{IV}}) = \sigma_\epsilon^2 (D'D)^{-1}$$

Estimador de Wald

$$D = \{0, 1\} \quad Z = \{0, 1\}$$

$$\begin{aligned}
\tau &= E[Y|D=1] - E[Y|D=0] \\
\delta &= E[D|Z=1] - E[D|Z=0] \\
\boxed{Y} &= D\tau + \epsilon \\
D &= Z\delta + \mu
\end{aligned}$$

$$Y = \alpha + \tau D_i + u$$

Z es un instrumento relevante y válido

Caso 1. Z es 1 solo instrumento Válido & Relevante

$$y = D\tau + u$$

$$\text{Cov}(y, z) = \text{Cov}(\alpha + \tau D_i + u, z) = \cancel{\text{Cov}(\alpha, z)} + \tau \text{Cov}(D_i, z) + \cancel{\text{Cov}(u, z)}$$

$$\hat{\tau}_{VI} = \frac{\text{Cov}(y, z)}{\text{Cov}(D, z)}$$

$$y = \pi_{10} + \pi_{11}z + \varepsilon_1$$

$$D = \pi_{20} + \pi_{21}z + \varepsilon_2$$

$$\hat{\pi}_{11} = (z'z)^{-1}z'y$$

$$\hat{\pi}_{21} = (z'z)^{-1}z'D$$

$$E[z'u|x] = 0$$

$$E[z'[y - D\tau]|x] = 0$$

↙

$$z'y - z'D\hat{\tau}_{VI} = 0$$

$$\hat{\tau}_{VI} = (z'D)^{-1}z'y \quad \checkmark$$

$$\hat{\tau}_{VI} = \frac{\hat{\pi}_{11}}{\hat{\pi}_{21}} \leftarrow \tau_{VI} = \frac{\text{Cov}(y, z) / \text{Var}(z)}{\text{Cov}(D, z) / \text{Var}(z)}$$

$$\hat{\tau}_{VI} = (z'D)^{-1}z'y = \frac{\text{Cov}(y, z) \rightarrow z'y}{\text{Cov}(D, z) \rightarrow z'D} (z'D)^{-1}z'y$$

Sesgado pero consistente $\{ E[\hat{\tau}_{VI}] \neq \tau, \text{plim}[\hat{\tau}_{VI}] = \tau$

Estimador de Wald

$$\hat{\tau}_{VI} = \text{Wald} = \frac{\bar{y}_{z=1} - \bar{y}_{z=0}}{\bar{D}_{z=1} - \bar{D}_{z=0}}$$

$$\begin{aligned} y &= \pi_{10} + \pi_{11}z + \varepsilon_1 \\ D &= \pi_{20} + \pi_{21}z + \varepsilon_2 \end{aligned}$$

Estimador de Wald

$$D = \begin{cases} 0 \\ 1 \end{cases} \quad Z = \begin{cases} 0 \\ 1 \end{cases}$$

$$\hat{\beta}_{\text{LSE}} = (Z'D)^{-1} Z'y$$

$$y = \pi_0 + \pi_1 z + u$$

$$\hat{\pi}_1 = E[y | z=1] - E[y | z=0]$$

$$\bar{y}_{z=1} - \bar{y}_{z=0}$$

$$D = \pi_2 + \pi_3 z + u$$


$$\hat{\pi}_3 = E[D | z=1] - E[D | z=0]$$

$$\hat{\beta}_{\text{LSE}} = \frac{\hat{\pi}_1}{\hat{\pi}_3} = \frac{E[y | z=1] - E[y | z=0]}{E[D | z=1] - E[D | z=0]}$$

PAUSA ACTIVA

$$D = \begin{cases} 1 & \text{Privado} \\ 0 & \text{Público} \end{cases}$$

$$\hat{y} = 50 + 9.67D$$



Asumamos que tenemos la siguiente información

	Público (D=0)	Privado (D=1)		Público (D=0)	Privado (D=1)
z=0	8000	1000	z=0	$E[y z=0, D=0] = 50$	$E[y z=0, D=1] = 60$
z=1	800	200	z=1	$E[y z=1, D=0] = 50$	$E[y z=1, D=1] = 58$

Calcule ① $E[y|D=1] =$

② $E[y|D=0] =$

③ $E[y|D=1] - E[y|D=0] =$

④ $E[D|z=1]$

⑤ $E[D|z=0] =$

⑥ Estimador de Wald

Ley de Esperanzas iteradas

$$E[y|D=d] = E[E[y|D, z]|D=d] \\ = \sum_z E[y|D=d, z=z] \cdot \Pr(z=z|D=d)$$

$$E[y|D=1] = E[y|D=1, z=0] \cdot \Pr(z=0|D=1) + E[y|D=1, z=1] \cdot \Pr(z=1|D=1)$$

$$E[y|D=0] = E[y|D=0, z=0] \cdot \Pr(z=0|D=0) + E[y|D=0, z=1] \cdot \Pr(z=1|D=0)$$

MC02E

$$y = D\tau + \varepsilon$$

$$D = Z\delta + u$$

$$\text{Cov}(Z, \varepsilon) = 0 \quad \text{Cov}(Z, D) \neq 0$$

Primera Etapa

a. Estimar $\hat{\delta}$ de la regresión $D = Z\delta + u$ $\hat{\delta} = (Z'Z)^{-1}Z'D$

b. Calcular $\hat{D} \Rightarrow \hat{D} = Z\hat{\delta} = Z(Z'Z)^{-1}Z'D = P_Z D$

Segunda Etapa

c. Reemplazar D por $\hat{D}$ en la ecuación principal y estimar la regresión $y = \hat{D}\tau + \varepsilon \rightarrow \hat{\tau}_{MC02E} = (\hat{D}'\hat{D})^{-1}\hat{D}'y$

d. $\hat{\tau}_{MC02E} = (D'P_Z D)^{-1}D'P_Z y$

$$\hat{\tau}_{MC02E} = (D'Z(Z'Z)^{-1}Z'D)^{-1}D'Z(Z'Z)^{-1}Z'y$$

$$E[\hat{\tau}_{MC02E}] \neq \tau$$

$$\text{plim}[\hat{\tau}_{MC02E}] = \tau$$

SESGADO

CONSISTENTE

Varianza

$$\hat{\tau}_{HCO2E} = (D' P_Z D)^{-1} D' P_Z y$$

$$= (D' P_Z D)^{-1} D' P_Z [D\tau + E]$$

$$= (D' P_Z D)^{-1} D' P_Z D\tau + (D' P_Z D)^{-1} D' P_Z E$$

$$= \tau + (D' P_Z D)^{-1} D' P_Z E$$

$$\text{Var}(\hat{\tau}_{HCO2E}) = \text{Var}(\tau + (D' P_Z D)^{-1} D' P_Z E)$$

$$= (D' P_Z D)^{-1} D' P_Z \text{Var}(E|X) P_Z' D (D' P_Z D)^{-1}$$

$\sigma_e^2 I_n$

$$= \sigma_e^2 (D' P_Z D)^{-1} D' P_Z P_Z' D (D' P_Z D)^{-1}$$

$$= \sigma_e^2 (D' P_Z D)^{-1} \underbrace{D' P_Z D}_{I_n} (D' P_Z D)^{-1}$$

$$= \sigma_e^2 (D' P_Z D)^{-1} \quad (\text{bajo homocedasticidad})$$

$$= \sigma_e^2 (D' P_Z D)^{-1} D' P_Z \Psi P_Z' D (D' P_Z D)^{-1} \quad (\text{bajo heterocedasticidad}).$$

Ejercicio: Demuestre que el estimador de HCO2E es igual que el estimador de Variables Instrumentales

$$(ABC)^{-1} = C^{-1}B^{-1}A^{-1}$$

$$\begin{aligned}\hat{\tau}_{HCO2E} &= (D'P_ZD)^{-1}D'P_Zy \\ &= (D'Z(Z'Z)^{-1}Z'D)^{-1}D'Z(Z'Z)^{-1}Z'y \\ &= (Z'D)^{-1}(Z'Z) \underbrace{(D'Z)^{-1}D'Z}_{I_n} (Z'Z)^{-1}Z'y \\ &= (Z'D)^{-1}(Z'Z)(Z'Z)^{-1}Z'y \\ &= (Z'D)^{-1}Z'y\end{aligned}$$

💡 Implicación: independientemente si el modelo está perfectamente identificado o NO se puede emplear siempre el estimador de HCO2E

★ Intrusión del Sesgo en los Estimadores de HCO2E.

$$Y = X\beta + \varepsilon$$

$$X = Z\delta + u$$

$$E[\hat{\beta}_{OLS}] = E[\hat{\beta}_{HCO2E}] \neq \beta \quad \text{incluso si } \text{cov}(Z, \varepsilon) = 0$$

No estaría sesgado si $\tilde{X} = \delta Z \Rightarrow y = \tilde{X}\beta + \varepsilon$

Problema $\hat{X} = \hat{\delta} Z$ y $\hat{X} \neq \tilde{X}$ por error muestral

☀ Pero $\hat{\beta}_{\text{V.I.}} = \beta + (Z'X)^{-1} Z' \varepsilon \frac{n}{n}$

$$plim(\hat{\beta}_{\text{V.I.}}) = plim(\beta) + plim\left(\frac{Z'X}{n}\right)^{-1} plim\left(\frac{Z'\varepsilon}{n}\right)$$

$$plim(\hat{\beta}_{\text{V.I.}}) = \beta + \underbrace{E[Z'X]}_{\neq 0}^{-1} \underbrace{E[Z'\varepsilon]}_{=0}$$

$$plim(\hat{\beta}_{\text{V.I.}}) = \beta. \text{ consistente}$$

1. Buscamos que los instrumentos NO sean débiles (estén altamente correlacionados con la variable endógena)

Señales de instrumentos débiles

- La correlación entre X y Z es baja
- El R² de la regresión de X contra Z es bajo
- En la primera etapa los instrumentos no son significativos ni individualmente ni conjuntamente

2. Buscamos que los instrumentos sean válidos (no estén correlacionados con el error)

No existe una prueba definitiva pero se pueden utilizar las siguientes aproximaciones

- Test de hausman

No estamos seguros que D sea endógena o exógena
 $E[D' u] \neq 0$ Endógena
 $E[D' u] = 0$ Exógena

$$\textcircled{1} \quad H = \frac{[\hat{\beta}_{\text{mco2E}} - \hat{\beta}_{\text{mco}}]^2}{[\text{Var}(\hat{\beta}_{\text{mco2E}}) - \text{Var}(\hat{\beta}_{\text{mco}})]^{1/2}} \sim \chi^2(K) \quad \text{↳ \# de variables Endógenas}$$

$$y = D\tau + \varepsilon$$

$$z = \begin{cases} 0 \\ 1 \end{cases} \quad \begin{aligned} \text{Cov}(z, \varepsilon) &= 0 \\ \text{Cov}(z, D) &\neq 0 \end{aligned}$$

$$\hat{\tau}_{IV} = \frac{\text{Cov}(y, z)}{\text{Cov}(D, z)} = \frac{\hat{\pi}_1}{\hat{\pi}_3}$$

$$\begin{aligned} y &= \pi_0 + \pi_1 z + u_y \quad \rightarrow \hat{\pi}_1 = E[y|z=1] - E[y|z=0] \\ D &= \pi_2 + \pi_3 z + u_D \quad \rightarrow \hat{\pi}_3 = E[D|z=1] - E[D|z=0] \end{aligned}$$

$$\tau_{WALD} = \frac{E[y|z=1] - E[y|z=0]}{E[D|z=1] - E[D|z=0]}$$

$r < p$ Sobrieidentificado más vars instr.
que var endógena (D)

~~$$\hat{\tau}_{IV} = (z'D)^{-1} z'y$$~~

$\begin{matrix} p \times n & n \times r & p \times n & n \times 1 \\ & \downarrow & & \\ & p \times r & & p \times 1 \end{matrix}$

MC02E

① $y = D\tau + \varepsilon$	Primera Etapa
② $D = z\delta + u$	$D = z\delta + u$
	$\hat{\delta} = (z'z)^{-1} z'D$

$$\begin{aligned}\hat{D} &= Z \hat{\delta} \\ &= Z (Z'Z)^{-1} Z' D\end{aligned}$$

segunda Etapa

$$y = \hat{D}\tau + e$$

$$\begin{aligned}\hat{\tau}_{no2E} &= (\hat{D}'\hat{D})^{-1} \hat{D}' y \\ &= \left((Z(Z'Z)^{-1}Z'D)' (Z(Z'Z)^{-1}Z'D) \right)^{-1} \\ &\quad (Z(Z'Z)^{-1}Z'D)' y \\ &= \underbrace{(D'Z(Z'Z)^{-1}Z'Z(Z'Z)^{-1}Z'D)^{-1}}_{(Z(Z'Z)^{-1}Z'D)' \tau' y}\end{aligned}$$

$$\begin{aligned}
 &= (D'Z'(Z'Z)^{-1}Z'D)^{-1} (Z(Z'Z)^{-1}Z'D)' y \\
 &= \underbrace{(D'Z)_{r \times n} \underbrace{(Z'Z)^{-1}_{n \times n}}_B \underbrace{(Z'D)'_{r \times n}}_C}_{A}^{-1} D'Z(Z'Z)^{-1}Z' y
 \end{aligned}$$

$$= (Z'D)^{-1} (Z'Z) \underbrace{(D'Z)^{-1} D'Z}_{I_n} (Z'Z)^{-1} Z' y$$

$$= (Z'D)^{-1} \underbrace{(Z'Z) (Z'Z)^{-1}}_{I_n} Z' y =$$

$$(Z'D)^{-1} Z' y \quad \checkmark$$

$$\begin{pmatrix} A & B & C \end{pmatrix}^{-1} \\
 C^{-1} B^{-1} A^{-1}$$

$E[\hat{\tau}_{HCOZE}] = \beta$ Sesgado
 $\text{plim}[\hat{\tau}_{HCOZE}] = \beta$ Consistente $\rightarrow \text{Var}(\hat{\tau}_{HCOZE}) = ??$